

Лекция 4. Генерация изображений: модели, конвейер text-to-image и параметры

Развёрнутый конспект на два академических часа. Дисциплина «Искусственный интеллект в креативных технологиях», магистратура 09.04.02, семестр 1

Table of Contents

Паспорт занятия.....	1
Как читать конспект	2
1. Задача и три идеи.....	2
2. Семейства порождающих моделей.....	2
3. Диффузия и латентное пространство	3
4. Конвейер text-to-image по компонентам	3
5. Параметры генерации: карта	4
6. Seed, шум и воспроизводимость (ЛР 5).....	4
7. Число шагов и дистилляция (ЛР 6).....	5
8. Масштаб управления.....	5
9. Размер кадра, структура запроса и язык	6
10. Планирование эксперимента и паспорт	7
11. Типичные заблуждения.....	7
12. Что делать в ЛР 5–6.....	7
Итоговый квиз.....	8
Выводы	9
Источники и дата проверки	10

Паспорт занятия

Параметр	Содержание
Номер и тема	лекция 4 «Генерация изображений: модели, конвейер text-to-image и параметры»
Место в курсе	семестр 1, четвёртая лекция из восьми; опирается на лекцию 3 (изображение как массив, PSNR, допуск) и лекцию 1 (паспорт эксперимента); открывает цикл о генерации: лекции 5–7 раскрывают отдельные семейства моделей
Длительность	2 академических часа (90 минут чистого времени)
Связанные ЛР	ЛР 5 «Запуск открытой модели text-to-image»; ЛР 6 «Исследование параметров text-to-image генерации»
Результаты обучения	1) называть семейства порождающих моделей изображений и их отличия; 2) описывать этапы конвейера text-to-image и назначение компонентов; 3) объяснять влияние seed, числа шагов, масштаба управления, размера кадра, структуры и языка запроса; 4) планировать контролируемый эксперимент и записывать паспорт запуска

Параметр	Содержание
Индикаторы компетенций	ПК-11.1 (безопасная и воспроизводимая работа с программными компонентами ИИ); ПК-6.1 (протокол эксперимента) — через наблюдаемые действия: студент фиксирует условия запуска, изменяет один фактор и сравнивает результат с допуском
Предварительные знания	лекции 1–3; ЛР 1–4

Как читать конспект

Текст можно изучать без слайдов. Теория дана вместе с измерениями, сделанными в лабораторных ЛР 5–6: модель SD Turbo запускалась в Google Colab на видеокarte Tesla T4 19.09.2026, значения помечены «ЛР 5» и «ЛР 6» или «прогон лекции». Остальные числа – арифметика по указанным формулам. В конце лекции 10 вопросов квиза; ключ вынесен в версию для лектора.

Три сквозных вопроса: **что в конвейере отвечает за эффект (механизм), что записать, чтобы результат можно было повторить (воспроизводимость), как убедиться, что параметр действительно помогает (измерение и допуск, лекция 3).**

1. Задача и три идеи

Пользователь пишет «афиша фестиваля робототехники, силуэт механической руки», а модель должна из случайного шума построить согласованное изображение из сотен тысяч пикселей. Трудностей две. Соответствие текста и картинки неоднозначно: одной фразе отвечает бесконечно много допустимых изображений, модель выбирает одно. Пространство изображений огромно, и перебор невозможен. Современные модели справляются, сочетая три идеи: обучение на больших наборах пар «изображение – описание»; итеративное построение результата из шума; работа не в пикселях, а в сжатом латентном пространстве.

2. Семейства порождающих моделей

Семейство	Как порождает	Сильные стороны	Ограничения	Лекция
Вариационные автокодировщики	декодируют точку латентного пространства в изображение	быстрая генерация, удобное латентное пространство	результаты часто размыты	5
Генеративно-состязательные сети	генератор превращает шум в изображение за один проход	очень быстрая генерация, высокая резкость	неустойчивое обучение, потеря разнообразия	7
Диффузионные модели	многошаговое удаление шума	высокое качество и разнообразие, устойчивое обучение	много шагов при генерации	6
Авторегрессионные модели	генерируют последовательность фрагментов по одному	единая архитектура для разных модальностей	длинные последовательности и для изображений	обзорно

Основа большинства современных систем «текст → изображение» – диффузионные модели в латентном пространстве (Rombach и др., arXiv:2112.10752). Это не одна модель, а конвейер из нескольких обученных компонентов и алгоритма, который ими управляет; ниже его состав разобран на примере SD Turbo – модели, которую студенты запускают в ЛР 5–6.

3. Диффузия и латентное пространство

Прямой процесс постепенно добавляет к изображению x_0 гауссов шум ε ; для шага t (Но и др., arXiv:2006.11239)

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, I),$$

где $\bar{\alpha}_t$ убывает от 1 (нет шума) до значения, близкого к 0 (чистый шум). **Обратный процесс** – то, что делает модель при генерации: сеть учится предсказывать шум $\hat{\varepsilon}_\theta(x_t, t, c)$ по текущему состоянию, номеру шага и описанию c ; планировщик вычитает его часть и переходит к x_{t-1} .

Латентное пространство. Работать с каждым пикселем дорого. Автокодировщик (VAE) сжимает изображение в латентный тензор, диффузия идёт в нём, а после последнего шага декодер возвращает пиксели. Для SD Turbo (прогон лекции): латентный тензор имеет 4 канала и в 8 раз меньшую сторону (vae_scale_factor равен 8), то есть для кадра 512×512 это $4 \times 64 \times 64$ чисел. Сжатие

$$\frac{3 \cdot 512 \cdot 512}{4 \cdot 64 \cdot 64} = \frac{786\,432}{16\,384} = 48$$

раз по числу значений; по данным авторов метода, перенос вычислений в такое пространство существенно снижает затраты при сохранении качества (Rombach и др.).

4. Конвейер text-to-image по компонентам

1. **Кодировщик текста.** Превращает запрос в последовательность векторов. В SD Turbo это CLIPTextModel (340,4 млн параметров), длина запроса – до 77 токенов (прогон лекции); более длинный текст усекается. Кодировщик обучен преимущественно на английских текстах (раздел 9).
2. **Начальный шум.** Случайный тензор в латентном пространстве; его значения определяются seed и генератором случайных чисел (раздел 6).
3. **Сеть шумоподавления.** UNet2DConditionModel (865,9 млн параметров): на каждом шаге оценивает шум с учётом текста. В новых моделях вместо U-Net используют трансформеры (Peebles, Xie, arXiv:2212.09748) и обучение по «поток» вместо шума (Lipman и др., arXiv:2210.02747); Stable Diffusion 3 сочетает то и другое (Esser и др., arXiv:2403.03206).
4. **Планировщик.** Определяет, какую долю шума удалять на каждом шаге. В SD Turbo – EulerDiscreteScheduler с шагами «trailing» (прогон лекции). Детерминированные планировщики, основанные на неявных диффузионных моделях, дают сопоставимое качество за существенно меньшее число шагов (Song и др., arXiv:2010.02502).
5. **Декодер VAE** (83,7 млн параметров) возвращает пиксели.

Общий вид: $x_T \sim \mathcal{N}(0, I)$, затем для $t = T, \dots, 1$

$$x_{t-1} = \text{Step}(x_t, \hat{\varepsilon}_\theta(x_t, t, c)),$$

и результат Decode(x_0). Каждый параметр из следующих разделов действует на один из этих элементов; знание этой карты позволяет объяснять результаты, а не подбирать их.

5. Параметры генерации: карта

Параметр	Что меняет	Как влияет	Типичный риск
Seed	начальный шум	какой из допустимых вариантов получится; воспроизводимость	сравнение формулировок запроса на одном seed обманчиво
Число шагов	число итераций удаления шума	больше шагов — точнее интегрирование и больше времени	избыточные шаги без выигрыша
Масштаб управления (guidance)	вес текстового условия	сильнее следование запросу, меньше разнообразия	пересыщение и артефакты
Размер кадра	размер латентного тензора	модель обучена на определённых размерах	искажения композиции
Запрос	вход кодировщика текста	содержание, стиль, детали	ожидание точного счёта и текста
Отрицательный запрос	вторая ветвь управления	отдаляет результат от описанного	нет эффекта, если управление выключено

6. Seed, шум и воспроизводимость (ЛР 5)

Начальный шум создаёт `torch.randn`; seed задаёт состояние генератора. Разные seed дают разные изображения: в прогоне лекции для четырёх seed по одному брифу PSNR между парами изображений составил 9,6–10,7 дБ (для сравнения: в ЛР 5 допуском «практически совпадает» принят PSNR не ниже 40 дБ).

Что показала ЛР 5 (Colab, Tesla T4, seed = 1000 + номер варианта; тридцать вариантов выполнены дважды, во втором сеансе на новой виртуальной машине):

- повтор запуска со свежим генератором и тем же seed даёт **побитово** то же изображение, SHA-256 демонстрационного результата совпал между сеансами;
- генератор на CPU и на GPU при одном seed дают **разные** изображения (PSNR 9–15 дБ): числа выдаёт разный генератор;
- float16 и float32 при одном seed дают **разные** изображения (PSNR 7–16 дБ). Причина – не точность сети, а шум: `torch.randn` для float16 и float32 выдаёт разные числа. Если подать в оба режима один и тот же шум, изображения близки (PSNR 37–51 дБ);
- первый элемент пакета из четырёх близок к одиночному запуску (PSNR 47–51 дБ), но не совпадает побитово;
- JPEG с качеством 90 вносит заметную численную потерю (PSNR 28–37 дБ) – эталон хранят без потерь (лекция 3).

Документация Diffusers рекомендует генератор на CPU и предупреждает, что объект `Generator` хранит состояние: один и тот же объект, переданный в два запуска, даёт разные результаты (в ЛР 5: второй запуск отличался, PSNR 11,14 дБ). Документация PyTorch указывает, что полная воспроизводимость между релизами, сборками и платформами не гарантируется. Вывод для практики: **паспорт запуска** содержит модель и ревизию, seed, устройство генератора, тип вычислений, планировщик, шаги, guidance, размер, версии библиотек и устройство; совпадение SHA-256 внутри зафиксированной среды – сильный тест, между платформами – не ожидается.

7. Число шагов и дистилляция (ЛР 6)

Классические модели требуют десятков шагов. **SD Turbo** – дистиллированная версия Stable Diffusion 2.1, обученная методом состязательной диффузионной дистилляции, который позволяет получать изображение за 1–4 шага (Sauer и др., arXiv:2311.17042); по карточке модели достаточно одного шага, рекомендуемый размер 512×512. Число шагов – компромисс между временем и деталями.

Результат прогона лекции (бриф 1, пять seed, 512×512, Tesla T4):

Шаги	Энергия границ	Контраст	Сходство CLIP	Время, с
1	0,0457	0,192	30,80	0,28
2	0,0778	0,247	30,55	0,36
3	0,0888	0,270	30,17	0,45
4	0,0920	0,278	30,29	0,54

Энергия границ (среднее значение модуля градиента яркости, ЛР 4) выросла примерно вдвое, контраст вырос на 44 %, время почти удвоилось; сходство с брифом по CLIP осталось в пределах разброса ($s \approx 2$) – то есть детали и контраст растут, а близость к запросу по этой метрике нет. В среднем по пяти брифам сходство CLIP при переходе от 1 к 4 шагам снизилось на 1,8 пункта. Вывод формулируется только для этой модели и метрик: «резче» не значит «лучше».

Пример из жизни 1. Скульптор и глыба. *Ситуация:* скульптор снимает лишнее слоями – сначала грубо, потом тонко; после «чернового» слоя фигура уже узнаётся, а тонкие слои добавляют детали. *Соответствие:* шаги удаления шума; у SD Turbo и одного «чернового» шага достаточно для узнаваемого результата. *Граница аналогии:* модель не «видит» цель заранее – она следует обученным правилам шага, и дополнительные шаги не гарантируют приближения к запросу.

8. Масштаб управления

Безклассификаторное управление (Ho, Salimans, arXiv:2207.12598) обучает одну сеть и с текстом, и без него; при генерации комбинируются две оценки шума. В форме, принятой в библиотеках,

$$\tilde{\epsilon} = \epsilon_{\theta}(x_t, \varnothing) + s (\epsilon_{\theta}(x_t, c) - \epsilon_{\theta}(x_t, \varnothing)),$$

где s – масштаб управления, $\varnothing$ – пустое условие. При $s = 1$ получается условная оценка без усиления, при $s > 1$ разница «с текстом и без» усиливается. В оригинальной статье вес w определён со сдвигом: $s = 1 + w$, поэтому значения из статьи и из библиотек напрямую не сравнивают. Авторы описывают компромисс: рост соответствия запросу ценой разнообразия. Отрицательный запрос использует ту же схему: вместо пустого условия подставляется нежелательное описание.

Что показали ЛР 5–6 и прогон лекции для SD Turbo.

- В Diffusers управление включается при $s > 1$. При `guidance_scale = 1,0` изображение **совпало побитово** с изображением при 0,0, а признак `do_classifier_free_guidance` равен False (ЛР 6).

- При `guidance_scale = 3,0` признак равен `True`, а изображение отличается от базового (PSNR 11,6 дБ); энергия границ и контраст растут во всех пяти брифах (в среднем +0,033 и +0,12), время растёт (+0,07 с) (ЛР 6).
- Отрицательный запрос при `guidance_scale = 0,0` **не влияет** на результат (SHA-256 совпал, прогон лекции); при 3,0 меняет изображение (PSNR 11,5 дБ).
- Итог: у SD Turbo рекомендованное значение 0,0; изучать `guidance` можно только вне рекомендованного режима, и вывод нельзя переносить на модели с обычным управлением.

Пример из жизни 2. Громкость усилителя. *Ситуация:* слегка повысить громкость – речь становится разборчивее, а слишком сильное усиление даёт хрип. *Соответствие:* растущий `s` усиливает следование запросу и одновременно контраст и артефакты. *Граница аналогии:* `guidance` не громкость: он усиливает разность двух оценок шума, а у дистиллированной модели этой ветви нет.

9. Размер кадра, структура запроса и язык

Размер. У модели есть «родной» размер (512×512). В ЛР 6 для первого брифа время генерации составило: 384×384 – 0,22 с, 512×512 – 0,34 с, 768×768 – 0,76 с (за пределами рекомендованного размера время растёт быстрее площади и появляются артефакты композиции). Метрики изображения при смене размера менялись непоследовательно (среднее изменение сходства CLIP: –0,05 при 384 и +0,32 при 768).

Структура запроса. Для изображения удобно пять частей: субъект; действие и композиция; среда и освещение; стиль и материал; технические ограничения (палитра, свободное место, «без текста»). В ЛР 6 замена короткого запроса («robotic arm poster») структурированным повысила сходство с брифом по CLIP в среднем на 6,1 пункта во всех пяти брифах.

Язык. Кодировщик текста SD Turbo обучен преимущественно на английских текстах. Замена английского запроса его русским переводом при неизменных остальных условиях снизила сходство с английским брифом в среднем на 17,6 пункта во всех пяти брифах (ЛР 6); энергия границ и контраст также снизились. Сходство CLIP при этом считалось всегда относительно английского брифа — единого эталона для обоих режимов.

Пример из жизни 3. Переводчик-посредник. *Ситуация:* заказ передан исполнителю через посредника, который знает язык хуже, чем исполнитель, – тонкие требования теряются. *Соответствие:* русский запрос обрабатывает кодировщик, ориентированный на английский язык; часть смысла не доходит до сети. *Граница аналогии:* кодировщик не «переводит» запрос — он строит векторы по обученным связям; потеря измерена как падение сходства по конкретной метрике, а не как «неправильный перевод».

Что не следует ожидать от запроса. Точный счёт объектов, читаемый текст на изображении и сложные пространственные отношения – известные трудные случаи; по карточке SD Turbo модель не выводит читаемый текст, а лица и люди могут получаться неверно. Если запрос исчерпал возможности, следующий шаг – дополнительное пространственное управление и дообучение (лекция 6), а не более длинная фраза.

10. Планирование эксперимента и паспорт

Цель ЛР 6 – превратить подбор картинки в эксперимент (лекции 1 и 3).

1. **Гипотеза** записывается до запуска: например, «увеличение числа шагов с 1 до 4 повысит детализацию и время, но не повысит сходство с брифом».
2. **Один фактор**: меняется только он; остальное фиксируется.
3. **Серия seed**: не менее пяти значений, одинаковых для обоих режимов.
4. **Метрики**: сходство с запросом (CLIP; Radford и др., arXiv:2103.00020), энергия границ, контраст, время. Для CLIP-сходства важно: оно измеряет соответствие текста и изображения в представлении CLIP, а не эстетику.
5. **Допуск** записывается до запуска: например, CLIP ± 1 ; энергия границ и контраст $\pm 10\%$; время $\pm 20\%$.
6. **Вывод**: по разности средних Δ , разбросу s по seed и допуску: $|\Delta| > 2s$ показывает выход эффекта за разброс, допуск – его практическую важность (лекция 3). Пример демо: энергия границ $\Delta = +0,046$ ($|\Delta|/s = 6,7$) – значимо и за допуском; CLIP $\Delta = -0,50$ ($|\Delta|/s = 0,36$) — в пределах допуска.

Локальный запуск и программный интерфейс. Локальный запуск открытой модели даёт контроль над версией весов и данными, но требует оборудования и проверки лицензии весов: для SD Turbo – Stability AI Community License Agreement (5 июля 2024 г.; коммерческое использование до 1 млн долларов дохода, регистрация, уведомление). Обращение по интерфейсу проще, но версию модели определяет поставщик, а данные передаются внешнему сервису.

11. Типичные заблуждения

- «**Больше шагов – всегда лучше**». У SD Turbo от 1 к 4 шагам растут детали и время, а сходство с запросом не растёт.
- «**Один seed – одно и то же изображение везде**». Между CPU и GPU, float16 и float32 изображения различны; воспроизводимость гарантируется внутри зафиксированной среды.
- «**guidance_scale = 1 чуть усиливает запрос**». У SD Turbo значения от 0 до 1 не меняют результат.
- «**Отрицательный запрос – надёжный фильтр**». При выключенном управлении он не влияет, при включённом лишь смещает результат.
- «**Русский запрос работает так же, как английский**». Для SD Turbo сходство с брифом падает в среднем на 17,6 пункта.
- «**Метрика выросла – значит, лучше**». Энергия границ растёт и от шума; оценка требует допуска и просмотра изображений.

12. Что делать в ЛР 5–6

ЛР 5. Запустить SD Turbo по закреплённой ревизии в Colab, сохранить result.png и manifest.json, сравнить два запуска, различающихся одним условием (повтор, seed, генератор, тип вычислений, формат файла, пакет), воспроизвести ошибку общего генератора. **ЛР 6.** Изменить один из шести факторов (шаги, размер меньше или больше, структура запроса,

guidance, язык), выполнить серию из пяти seed, заполнить таблицу метрик, сравнить с допуском, записанным до запуска. Каждая работа выполняется в отдельном блокноте.

Итоговый квиз

Проверьте усвоение: в каждом из десяти вопросов верен один из четырёх вариантов. Подсказка направляет рассуждение, не раскрывая ответа; ключ и разбор приведены в версии для лектора.

Вопрос 1. Какое семейство моделей порождает изображение многошаговым удалением шума?

- A) диффузионные модели
- B) вариационные автокодировщики, декодирующие точку латентного пространства
- C) генеративно-состязательные сети, работающие за один проход
- D) авторегрессионные модели, строящие последовательность фрагментов.

Подсказка: прямой процесс добавляет шум, обратный убирает.

Вопрос 2. Во сколько раз латентное представление $4 \times 64 \times 64$ содержит меньше чисел, чем изображение $3 \times 512 \times 512$?

- A) в 6 раз
- B) в 12 раз
- C) в 24 раза
- D) в 48 раз.

Подсказка: разделите число значений пикселей на число значений латентного тензора.

Вопрос 3. Что задаёт seed при неизменных остальных условиях запуска?

- A) веса модели, загруженные из репозитория
- B) начальный шум, из которого строится изображение
- C) текст запроса, поданный в кодировщик
- D) число шагов планировщика.

Подсказка: именно это различается у разных изображений при одном запросе.

Вопрос 4. При одном seed изображения в float16 и float32 различны. Что явилось основной причиной в ЛР 5?

- A) сеть в float16 хуже выполняет свёртки
- B) в float16 загружаются другие веса модели
- C) torch.randn выдаёт разные числа для разных типов данных, поэтому начальный шум разный
- D) JPEG сжимает изображения по-разному.

Подсказка: при одинаковом шуме PSNR между режимами оказался 37–51 дБ.

Вопрос 5. Что возвращает формула масштаба управления при $s = 1$?

- A) условную оценку шума $\varepsilon_{\theta}(x_t, c)$
- B) безусловную оценку $\varepsilon_{\theta}(x_t, \emptyset)$
- C) нулевой вектор
- D) удвоенную разность оценок.

Подсказка: подставьте $s = 1$ в $\varepsilon_{\theta}(x_t, \emptyset) + s(\varepsilon_{\theta}(x_t, c) - \varepsilon_{\theta}(x_t, \emptyset))$.

Вопрос 6. Как связаны вес w в статье Но и Salimans и масштаб s в библиотеках?

- A) $s = w$
- B) $s = w^2$
- C) $s = 1 + w$
- D) $s = 1 - w$.

Подсказка: при $w = 0$ должна получаться обычная условная модель.

Вопрос 7. У SD Turbo guidance_scale = 1,0 вместо 0,0: что показала ЛР 6?

- A) изображение совпало побитово с изображением при 0,0, управление выключено
- B) изображение стало немного ярче
- C) время выросло вдвое
- D) возникла ошибка загрузки модели.

Подсказка: проверьте pipe.do_classifier_free_guidance.

Вопрос 8. Что показал переход с 1 на 4 шага для брифа 1 в ЛР 6?

- A) сходство CLIP значимо выросло
- B) энергия границ выросла примерно вдвое, а сходство CLIP осталось в пределах допуска
- C) время генерации не изменилось
- D) контраст снизился.

Подсказка: сравните Δ и допуск ± 1 для CLIP.

Вопрос 9. Как изменилось сходство с английским брифом по CLIP при замене английского запроса русским переводом (среднее по пяти брифам)?

- A) не изменилось
- B) выросло примерно на 6 пунктов
- C) снизилось примерно на 18 пунктов
- D) выросло примерно на 18 пунктов.

Подсказка: кодировщик текста обучен преимущественно на английских текстах.

Вопрос 10. Почему сравнение двух формулировок запроса на одном seed ненадёжно?

- A) seed изменяет веса модели
- B) при одном seed формулировки обязаны давать одинаковый результат
- C) время генерации зависит только от seed
- D) эффект формулировки зависит от начального шума, поэтому нужна серия seed.

Подсказка: разные seed дают разные изображения при одном запросе.

Шкала самопроверки: 9–10 верных – тема освоена; 7–8 – повторить разделы 6–8; менее 7 – перечитать конспект и вернуться к ЛР 5–6.

Выводы

1. Text-to-image – конвейер из кодировщика текста, сети шумоподавления, планировщика и декодера; диффузия идёт в латентном пространстве, в 48 раз меньшем, чем пиксельное.
2. Воспроизводимость обеспечивается паспортом запуска: модель и ревизия, seed, устройство генератора, тип вычислений, шаги, guidance, размер, версии; между платформами она не гарантируется.

3. Число шагов – компромисс времени и деталей; у дистиллированной SD Turbo достаточно одного шага, и рост числа шагов не повышал сходство с запросом.
4. Масштаб управления работает при $s > 1$; у SD Turbo рекомендовано 0,0, значения от 0 до 1 не влияют, отрицательный запрос при выключенном управлении не действует.
5. Структура запроса и язык влияют сильнее, чем размер кадра: структурированный запрос – плюс 6,1 пункта, русский – минус 17,6.
6. Вывод об эффекте параметра делается по серии seed, разности средних, критерию $2s$ и допуску, записанному до запуска.

Источники и дата проверки

1. Rombach R. и др. High-Resolution Image Synthesis with Latent Diffusion Models (arXiv:2112.10752, 20.12.2021).
2. Ho J. и др. Denoising Diffusion Probabilistic Models (arXiv:2006.11239, 19.06.2020).
3. Song J. и др. Denoising Diffusion Implicit Models (arXiv:2010.02502, 06.10.2020).
4. Ho J., Salimans T. Classifier-Free Diffusion Guidance (arXiv:2207.12598, 26.07.2022).
5. Sauer A. и др. Adversarial Diffusion Distillation (arXiv:2311.17042, 28.11.2023).
6. Peebles W., Xie S. Scalable Diffusion Models with Transformers (arXiv:2212.09748, 19.12.2022).
7. Lipman Y. и др. Flow Matching for Generative Modeling (arXiv:2210.02747, 06.10.2022).
8. Esser P. и др. Scaling Rectified Flow Transformers for High-Resolution Image Synthesis (arXiv:2403.03206, 05.03.2024).
9. Radford A. и др. Learning Transferable Visual Models From Natural Language Supervision (arXiv:2103.00020, 26.02.2021).
10. Карточка модели stabilityai/sd-turbo и файл LICENSE.md (Hugging Face); документация Diffusers «Reproducibility»; документация PyTorch «Reproducibility». Проверено 19.09.2026.
11. Журналы выполнения ЛР 5 и ЛР 6 и прогона лекции: Google Colab, Tesla T4, Python 3.13.15, torch 2.11.0+cu128, diffusers 0.40.0, transformers 5.16.1, 19.09.2026.

Публикации проверены по страницам препринтов 19.09.2026 (название, первый автор, дата); формулы – стандартные определения; измерения – из журналов выполнения.