

Лекция 5. Автокодировщики и латентное пространство

Развёрнутый конспект на два академических часа. Дисциплина «Искусственный интеллект в креативных технологиях», магистратура 09.04.02, семестр 1

Table of Contents

Паспорт занятия.....	1
Как читать конспект	2
1. Сжатие и порождение	2
2. Автокодировщик и узкое место	2
3. Размер латентного вектора и эталон.....	3
4. Что меняет фактор: результаты 30 вариантов ЛР 7	3
5. Шумоподавляющий автокодировщик	4
6. Вариационный автокодировщик.....	4
7. Вес β и схлопывание	5
8. Сэмплирование и интерполяция	5
9. Дискретные коды и латентное пространство в Stable Diffusion	6
10. Типичные заблуждения.....	7
11. Что делать в ЛР 7–8.....	7
Итоговый квиз.....	7
Выводы	9
Источники и дата проверки	10

Паспорт занятия

Параметр	Содержание
Номер и тема	лекция 5 «Автокодировщики и латентное пространство»
Место в курсе	семестр 1, пятая лекция из восьми; опирается на лекции 3 (изображение как массив, PSNR) и 4 (латентное пространство в Stable Diffusion, воспроизводимость); открывает разбор семейств порождающих моделей: лекции 6 и 7 — диффузионные модели и GAN
Длительность	2 академических часа (90 минут чистого времени)
Связанные ЛР	ЛР 7 «Построение автокодировщика»; ЛР 8 «Генерация и интерполяция в латентном пространстве»
Результаты обучения	1) описывать устройство автокодировщика и роль узкого места; 2) объяснять, чем вариационный автокодировщик отличается от обычного и зачем нужен KL-член; 3) выбирать вес β и размер латентного вектора по измерениям; 4) строить и оценивать сэмплирование и интерполяцию в латентном пространстве; 5) узнавать схлопывание апостериорного распределения
Индикаторы компетенций	ПК-6.1 (протокол эксперимента); ПК-11.1 (безопасная и воспроизводимая работа с программными компонентами ИИ) — через наблюдаемые действия: студент сопоставляет результат с эталоном, изменяет один фактор и записывает серию seed

Параметр	Содержание
Предварительные знания	лекции 1–4; ЛР 1–6

Как читать конспект

Конспект самодостаточен: его можно читать без слайдов. Теорию сопровождают измерения из лабораторных работ: автокодировщики из ЛР 7 обучались в Google Colab на видеокarte Tesla T4, вариационные автокодировщики из ЛР 8 – в среде Engage на процессоре (19–20.09.2026) на синтетических сценах (диски и полосы на градиентном фоне), значения помечены «ЛР 7» или «ЛР 8». Прочие числа получены арифметикой по приведённым формулам. Лекцию завершает квиз из десяти вопросов; ключ с разбором помещён только в версию для лектора.

Три сквозных вопроса: **что сохраняется в латентном векторе** (ёмкость), **что заставляет латентное пространство быть пригодным для порождения** (регуляризация), **как убедиться, что результат лучше тривиального** (эталон и серия seed, лекция 3).

1. Сжатие и порождение

Две задачи выглядят по-разному, но решаются одним приёмом. **Сжатие**: записать изображение малым числом чисел так, чтобы его можно было восстановить. **Порождение**: получить новое изображение, которого не было в наборе. Автокодировщик учится первому, а если латентные векторы организованы правильно, то и второму: точка между двумя закодированными изображениями декодируется в правдоподобную промежуточную сцену.

Пример из ЛР 7: сцена размером $3 \times 32 \times 32 = 3072$ числа, а порождена она тремя факторами (положение диска по x и y , радиус). Всё изображение можно было бы записать тремя числами; сеть должна сама найти такое сжатие.

2. Автокодировщик и узкое место

Автокодировщик состоит из кодировщика E и декодировщика D ; $z = E(x)$ – латентный вектор из d чисел, $\hat{x} = D(z)$ – восстановление. Обучение минимизирует ошибку реконструкции

$$\mathcal{L}_{AE} = \frac{1}{n} \|x - D(E(x))\|^2,$$

то есть вход служит и целью. Это **обучение без учителя**: размеченных данных не требуется. **Узкое место** (d существенно меньше размерности входа) заставляет сеть оставить в z только существенное. Если d не меньше размерности входа, возможно тождественное отображение – сеть не узнаёт ничего полезного.

Устройство сети из ЛР 7: кодировщик – три свёртки ($3 \rightarrow 16 \rightarrow 32 \rightarrow 64$ каналов, шаг 2) и линейный слой в d чисел; декодировщик – линейный слой и три транспонированные свёртки с сигмоидой на выходе. При $d = 8$ в модели 101,0 тыс. параметров (ЛР 7).

Качество реконструкции измеряется PSNR (лекция 3). На тесте (1024 сцены набора «диск», не участвовавшие в обучении) сеть с $d = 8$ достигает около 26 дБ (ЛР 7, среднее по пяти seed 26,0–26,1 дБ, разброс между seed $s = 0,7$ дБ). Обучение одной модели на GPU T4

занимает около двух секунд (то же обучение на процессоре Engage при одном потоке – около 47 секунд).

3. Размер латентного вектора и эталон

Одна цифра PSNR ничего не говорит без **эталона**. В ЛР 7 эталоном служит «средняя картинка»: одно и то же изображение (среднее по обучающей выборке) выдаётся на любой вход. На наборе «диск» оно даёт на тесте 17,2 дБ, потому что фон занимает большую часть кадра и у всех сцен одинаков. Модель с $d = 2$ даёт 23,2 дБ (выигрыш относительно эталона 6,0 дБ), модель с $d = 8$ – 26,0 дБ (выигрыш 8,8 дБ).

Развёртка по размеру латентного вектора (ЛР 7, вариант 1, среднее по seed 101–103):

d	1	2	3	4	8
PSNR, дБ	20,6	23,2	25,2	26,5	25,7

Качество растёт до $d = 3-4$ и дальше не растёт (различие между $d = 4$ и $d = 8$ меньше разброса между seed). Набор «диск» имеет три независимых фактора; вектор из двух чисел не может их закодировать, и на изображениях режима $d = 2$ радиус диска у разных сцен почти одинаков. Общее правило: размер горлышка должен быть не меньше числа независимых факторов, которые нужно сохранить; нужное d определяют развёрткой.

Пример из жизни 1. Чемодан на неделю. *Ситуация:* в маленький чемодан нужно уложить вещи на неделю; в него влезает набор самого необходимого, а всё, что не вошло, придётся восстанавливать по памяти. *Соответствие:* латентный вектор – чемодан, реконструкция — попытка «достать» вещи из него; слишком маленький чемодан теряет важное, слишком большой не заставляет выбирать. *Граница аналогии:* автокодировщик не выбирает вещи по важности заранее – набор «необходимого» определяется тем, что уменьшает ошибку реконструкции на обучающих данных.

4. Что меняет фактор: результаты 30 вариантов ЛР 7

В ЛР 7 для пяти наборов сцен и шести факторов измерены отклики по серии из пяти seed (19.09.2026). Основные закономерности (значения – диапазоны по пяти наборам):

- **Размер горлышка** (d : $8 \rightarrow 2$): PSNR падает на 1,7–5,6 дБ; критерий $|D| > 2s$ выполнен в 4 наборах из 5. Рост до $d = 32$ даёт +0,6 ... + 1,5 дБ, критерий выполнен в одном наборе из пяти.
- **Архитектура:** полносвязная сеть при том же горлышке имеет 1580,6 тыс. параметров вместо 101,0 (в 15,6 раза), обучается быстрее (1,3–1,4 с вместо 2,1 с), а разрыв «обучение – тест» больше во всех пяти наборах (на 0,08–0,13 дБ).
- **Функция потерь:** при замене MSE на L1 за 20 эпох PSNR ниже до 10,9 дБ. Причина – скорость сходимости, а не предел качества: при L1 в варианте 1 PSNR равен 16,2 дБ после 20 эпох, 19,2 после 60 и 26,3 после 120 (MSE: 25,7 после 20 эпох и 28,1 после 60).
- **Объём выборки:** при 512 сценах и том же числе шагов обучения (160 эпох) PSNR на тесте почти не меняется, а разрыв «обучение – тест» растёт на 0,11–0,54 дБ во всех наборах. При 20 эпохах вместо 160 PSNR падает на 9 дБ из-за недообучения – эксперимент измерял бы не объём данных, а число шагов.

Вывод: сравнение факторов при фиксированном числе эпох смешивает эффект фактора со скоростью обучения; при изменении объёма выборки или функции потерь это нужно проверять контрольным прогоном.

5. Шумоподавляющий автокодировщик

Шумоподавляющий автокодировщик обучается на искажённых входах: $\tilde{x} = x + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$, а цель – исходное x . Сеть, не способная скопировать вход (в нём шум, а в цели его нет), вынуждена выучить структуру данных. В ЛР 7 для набора «диск» при шуме $\sigma = 0,2$ на входе: обычная сеть, обученная на чистых данных, даёт на зашумлённых входах 22,5 дБ (разброс между seed 3,7 дБ), шумоподавляющая – 25,6 дБ; отличие +3,1 дБ, но критерий $|Δ| > 2s$ не выполнен из-за разброса режима А ($|Δ|/s = 0,8$). По пяти наборам сцен PSNR растёт на 1,1–3,1 дБ, критерий выполнен в двух наборах из пяти.

Пример из жизни 2. Реставратор. *Ситуация:* реставратор восстанавливает фреску по повреждённому фрагменту: он знает, как обычно выглядит роспись этой эпохи, и убирает царапины, а не копирует их. *Соответствие:* шумоподавляющая сеть учится по повреждённому входу восстанавливать чистую цель, поэтому шум не попадает в выход. *Граница аналогии:* сеть не знает эпохи и стиля – она восстанавливает то, что часто встречалось в её обучающих данных, и может «дорисовать» несуществующее.

6. Вариационный автокодировщик

У обычного автокодировщика латентные векторы лежат там, куда их поместило обучение; никто не гарантирует, что декодировщик умеет работать в остальных точках. **Вариационный автокодировщик** (VAE; Kingma, Welling, arXiv:1312.6114; подробный разбор – Doersch, arXiv:1606.05908) устроен так, чтобы латентное пространство было пригодно для порождения.

Кодировщик выдаёт распределение. Вместо одной точки z кодировщик возвращает среднее $\mu(x)$ и логарифм дисперсии $\log \sigma^2(x)$ по каждой из d осей: $q(z | x) = \mathcal{N}(\mu, \text{diag} \sigma^2)$. **Приём репараметризации.** Точка берётся как $z = \mu + \sigma \odot \varepsilon$, где $\varepsilon \sim \mathcal{N}(0, I)$: случайность вынесена в ε , и градиент проходит через μ и σ . **Потери** на одно изображение:

$$\mathcal{L} = \underbrace{\|x - \hat{x}\|^2}_{\text{реконструкция}} + \beta \underbrace{\text{KL}(q(z | x) \| \mathcal{N}(0, I))}_{\text{регуляризация}}, \quad \text{KL} = -1/2 \sum_j (1 + \log \sigma_j^2 - \mu_j^2 - \sigma_j^2).$$

Первое слагаемое требует, чтобы по z можно было восстановить x ; второе тянет каждое распределение $q(z | x)$ к стандартному нормальному. Так все закодированные изображения оказываются в одной области вокруг нуля, между ними нет «дыр», а сэмплы из $\mathcal{N}(0, I)$ попадают туда, где декодировщик обучался. При $\beta = 1$ и гауссовом декодировщике с дисперсией 1/2 на пиксель потери равны (с точностью до постоянной) отрицательной нижней границе правдоподобия из работы Kingma и Welling.

Малый пример для проверки счёта. Для одной оси с $\mu = 0,5$, $\sigma = 1$: $\text{KL} = -1/2 (1 + 0 - 0,25 - 1) = 0,125$ нат; для оси с $\mu = 0$, $\sigma = 1$ KL равен нулю — такая ось не несёт информации о входе.

Эксперимент ЛР 8: сэмплы из $\mathcal{N}(0, I)$. На наборе «диск» (seed 101) разброс средних μ по осям у обычного автокодировщика 2,0–4,9, у вариационного 0,2–1,0. Сэмплы,

полученные декодированием $z \sim \mathcal{N}(0, I)$, близки к тестовым сценам на 23,3 дБ (PSNR ближайшей тестовой сцены) у VAE и лишь на 12,9 дБ у обычного автокодировщика; по пяти наборам сцен и пяти seed различие 8,3–10,5 дБ во всех наборах (критерий $|\Delta| > 2s$ выполнен 5 раз из 5). На comparison.png сэмплы обычного автокодировщика – пятна без структуры, сэмплы VAE – диски, хотя часть из них размыта или вытянута. Реконструкция при этом у VAE чуть хуже (на 0,2–1,9 дБ): регуляризация имеет цену. *Осторожность*: PSNR ближайшего соседа не измеряет разнообразие; при уменьшении d до 2 он вырос на 1,2 дБ в наборе «диск» (сэмплы «упрощаются» и оказываются ближе к тестовым сценам), хотя качество реконструкции упало.

7. Вес β и схлопывание

Вес β – цена информации в латентном векторе: чем он больше, тем менее охотно сеть кодирует детали. Для регуляризации в этом духе предложено и «постепенное» увеличение допустимой информации в латентном векторе (Burgess и др., arXiv:1804.03599: «progressively increases the information capacity of the latent code»).

Схлопывание апостериорного распределения (posterior collapse): кодировщик выдаёт для любого входа почти одно и то же распределение, близкое к $\mathcal{N}(0, I)$; $KL \approx 0$, декодировщик выдаёт «среднюю» картинку. В ЛР 8 обучение VAE с $\beta = 1$ сразу (без разогрева) для набора «диск» на пяти seed дало реконструкцию 26,5; 17,2; 25,7; 26,7; 24,7 дБ (средняя картинка даёт 17,2 дБ; для seed 102 R^2 факторов по μ равно $-0,001$, а разброс μ по всем осям равен нулю). Среднее 24,2 при разбросе 4,0 дБ скрывает один схлопнувшийся запуск. Простой способ борьбы – **разогрев KL-члена**: вес растёт линейно от 0 до β за первые 10 эпох; с разогревом реконструкция во всех пяти seed 25,6–26,9 дБ. Авторы VQ-VAE (van den Oord и др., arXiv:1711.00937) указывают на дискретные латентные коды как на способ обойти схлопывание (раздел 9).

Эксперимент ЛР 8: $\beta = 1 \rightarrow 8$. Набор «диск», пять seed:

Показатель	$\beta = 1$	$\beta = 8$	Δ	$ \Delta /s$
реконструкция, дБ	26,37	22,53	–3,84	6,26
интерполяция, дБ	22,55	21,90	–0,65	1,34
сэмплы, дБ	23,24	23,21	–0,03	0,06
R^2 факторов	0,899	0,786	–0,114	5,19

При $\beta = 8$ активны лишь 2 оси из 8 (разброс μ около 0,9 у двух осей и не выше 0,16 у остальных), тогда как сцена задаётся тремя факторами; при $\beta = 1 - 7$ из 8. Поэтому реконструкция и линейная связь осей с факторами ухудшились, а интерполяция и сэмплы не улучшились. По пяти наборам сцен реконструкция падает во всех (от $-7,7$ до $-2,3$ дБ), R^2 – в четырёх из пяти. Вывод: увеличение β не обязано «улучшать» пространство; выбор делают по измерениям, а не по названию метода.

8. Сэмплирование и интерполяция

Сэмплирование. $z \sim \mathcal{N}(0, \tau^2 I)$, затем $\hat{x} = D(z)$; τ – «температура». При $\tau = 2$ (сэмплы вне области, где обучалась модель) близость сэмплов к тестовым сценам падает на 1,3–2,7 дБ во всех пяти наборах, критерий $2s$ выполнен 5 раз из 5.

Интерполяция. Для закодированных изображений z_a, z_b путь $z_t = (1 - t)z_a + tz_b$ (линейный) или сферический

$$z_t = \frac{\sin((1-t)\Omega)}{\sin\Omega} z_a + \frac{\sin(t\Omega)}{\sin\Omega} z_b, \quad \cos\Omega = \frac{z_a \cdot z_b}{\|z_a\| \|z_b\|}.$$

Сферический путь сохраняет длину вектора и применяется к гауссовым сэмплам. В ЛР 8 качество интерполяции измеряется по трём точкам пути ($t = 0,25; 0,5; 0,75$) относительно сцены, построенной по средним значениям факторов пары; эталон известен, потому что сцены порождаются кодом. Результаты:

- **Линейная и сферическая.** Сферическая интерполяция оказалась чуть хуже линейной (от $-0,5$ до $-0,2$ дБ), значимо — ни в одном наборе. Основание для «более качественной» сферической интерполяции на этих данных не найдено.
- **Обычный и вариационный автокодировщик.** Интерполяция между закодированными сценами у обычного автокодировщика работает так же (22,63 и 22,53 дБ, среднее по пяти seed, набор «диск»): KL-член нужен для порождения из $\mathcal{N}(0, I)$, а не для интерполяции между известными точками.
- **Размер горлышка.** При $d = 2$ интерполяция в наборе «диск» не хуже, чем при $d = 8$, но R^2 падает до 0,65: недостающий фактор не восстанавливается.

Пример из жизни 3. Переход между двумя эскизами. *Ситуация:* дизайнеру нужен промежуточный вариант между двумя эскизами; наложение с прозрачностью 50 % даёт двойной контур, а «среднее по параметрам» (положение, размер, цвет) — новый чёткий вариант. *Соответствие:* смешивание пикселей соответствует наложению, латентная интерполяция — усреднению параметров сцены, если сеть выделила их в латентном пространстве. *Граница аналогии:* оси латентного вектора не обязаны совпадать с понятными параметрами; в ЛР 8 линейная восстановимость факторов (R^2) для набора «диск» 0,90, а для набора «цветной диск» 0,57 — хуже, потому что оттенок периодичен.

9. Дискретные коды и латентное пространство в Stable Diffusion

Дискретные латентные коды. В VQ-VAE (van den Oord и др., arXiv:1711.00937) кодировщик выбирает для каждого фрагмента ближайший вектор из обучаемого словаря; латентное представление — набор номеров из словаря. По утверждению авторов, такой подход обходит проблему схлопывания апостериорного распределения и даёт качественную генерацию изображений, видео и речи. Для вариационных автокодировщиков с непрерывным пространством практический вывод из раздела 7 остаётся прежним: схлопывание — реальный режим отказа, и его проверяют по каждому seed.

Связь с Stable Diffusion (лекция 4). Конвейер text-to-image использует автокодировщик: кодировщик сжимает изображение в латентный тензор $4 \times 64 \times 64$ (в 48 раз меньше по числу значений, чем $3 \times 512 \times 512$), диффузия идёт в нём, декодировщик возвращает пиксели (Rombach и др., arXiv:2112.10752). Качество итогового изображения ограничено реконструкцией автокодировщика: потери при кодировании нельзя исправить диффузией, поэтому в карточке SD Turbo отмечены потери при автокодировании. Обучение самого автокодировщика — та же схема, что в ЛР 7–8, с очень большим числом изображений; принципы (эталон, серия seed, диагностика схлопывания) переносятся.

10. Типичные заблуждения

- «**Чем больше латентный вектор, тем лучше**». В ЛР 7 рост d с 8 до 32 дал +0,6...+1,5 дБ и значим лишь в одном наборе из пяти; в ЛР 8 при $\beta = 1$ реконструкция при $d = 32$ хуже (−1,7...−0,3 дБ), а R^2 растёт.
- «**Высокий PSNR — хорошая модель**». Средняя картинка даёт 17,2 дБ; значение нужно сравнивать с эталоном.
- «**Любой автокодировщик порождает изображения**». Сэмплы из $\mathcal{N}(0, I)$ у обычного автокодировщика на 8,3–10,5 дБ хуже, чем у вариационного.
- «**Больше β — чище пространство**». При $\beta = 8$ активны 2 оси из 8; реконструкция падает на 3,8 дБ, интерполяция не улучшается.
- «**Сферическая интерполяция всегда лучше**». На данных ЛР 8 она чуть хуже линейной, значимой разницы нет.
- «**L1 хуже MSE**» и «**на малой выборке всегда хуже**». При равном числе эпох L1 отстаёт из-за скорости сходимости (16,2; 19,2; 26,3 дБ после 20; 60; 120 эпох), а при сокращении выборки до 512 и том же числе шагов растёт разрыв «обучение – тест», а не PSNR на тесте.

11. Что делать в ЛР 7–8

ЛР 7. В новом блокноте собрать свёрточный автокодировщик, измерить PSNR на тесте и разрыв «обучение – тест», сравнить с эталоном «средняя картинка», изменить один из шести факторов (размер латентного вектора, архитектура, функция потерь, шумоподавляющий вход, объём выборки), выполнить серию из пяти seed и сравнить с допуском, записанным до запуска. **ЛР 8.** В отдельном блокноте обучить вариационный автокодировщик, измерить реконструкцию, интерполяцию, сэмплы и R^2 , изменить один из шести факторов (β , тип модели, размер вектора, способ интерполяции, разброс сэмплов), диагностировать активные оси и воспроизвести схлопывание. ЛР 7 выполняется в отдельном блокноте Colab, ЛР 8 – в отдельной папке Engage.

Итоговый квиз

Десять вопросов проверяют раздел за разделом; в каждом верен один вариант из четырёх. Подсказка задаёт направление рассуждения и не называет ответ; правильные варианты и пояснения есть в версии для лектора.

Вопрос 1. Что заставляет автокодировщик оставлять в латентном векторе только существенное?

- A) увеличение числа эпох
- B) узкое место – число чисел в латентном векторе меньше размерности входа
- C) сигмоида на выходе декодировщика
- D) размер пакета.

Подсказка: что произойдёт, если латентный вектор не короче входа?

Вопрос 2. Сцена набора «диск» порождается тремя независимыми факторами. Каково наименьшее d , при котором информация теоретически не теряется?

- A) 1
- B) 2
- C) 8
- D) 3.

Подсказка: сколько чисел нужно, чтобы записать положение по двум осям и радиус?

Вопрос 3. PSNR модели с $d = 2$ равен 23,2 дБ, а «средней картинке» – 17,2 дБ. Каков выигрыш относительно эталона?

- A) 6,0 дБ
- B) 23,2 дБ
- C) 40,4 дБ
- D) 17,2 дБ.

Подсказка: выигрыш — разность значений.

Вопрос 4. Почему в факторе «512 вместо 4096 сцен» ЛР 7 увеличивает число эпох до 160?

- A) чтобы увеличить объём данных
- B) чтобы сократить время
- C) чтобы сохранить число шагов обучения (640)
- D) чтобы любой ценой повысить PSNR.

Подсказка: сколько шагов делается за эпоху при пакете 128 и размере выборки 512?

Вопрос 5. Что служит целью при обучении шумоподавляющего автокодировщика?

- A) зашумлённый вход
- B) исходное чистое изображение
- C) случайный шум
- D) среднее по выборке.

Подсказка: сеть должна научиться отбрасывать шум.

Вопрос 6. Зачем в VAE используется приём репараметризации $z = \mu + \sigma \odot \varepsilon$?

- A) чтобы градиент проходил через μ и σ , вынося случайность в ε
- B) чтобы ускорить сэмплирование
- C) чтобы сократить число параметров
- D) чтобы обнулить KL-член.

Подсказка: через случайную операцию градиент напрямую не проходит.

Вопрос 7. Чему равен KL для одной оси с $\mu = 0,5$ и $\sigma = 1$?

- A) 0,5 нат
- B) 0,25 нат
- C) 1,0 нат

D) 0,125 нат.

Подсказка: подставьте в $-1/2 (1 + \log \sigma^2 - \mu^2 - \sigma^2)$.

Вопрос 8. Почему в ЛР 8 сэмплы из $\mathcal{N}(0, I)$ у обычного автокодировщика хуже (12,9 дБ против 23,3 дБ)?

A) слишком мало эпох

B) слишком большой β

C) средние μ обычного автокодировщика разбросаны шире $\mathcal{N}(0, I)$ (2,0–4,9 против 0,2–1,0), и сэмплы попадают в область, где декодировщик не обучался

D) в декодировщике нет сигмоиды.

Подсказка: сравните разброс μ по осям у двух моделей.

Вопрос 9. При обучении VAE ($\beta = 1$, без разогрева) для seed 102 PSNR реконструкции равен 17,2 дБ, а $R^2 \approx 0$. Что произошло?

A) схлопывание апостериорного распределения: латентный вектор не несёт информации о сцене

B) переобучение

C) взрыв градиента

D) ошибка в данных.

Подсказка: какой PSNR даёт эталон «средняя картинка»?

Вопрос 10. Какой результат получен в ЛР 8 при замене линейной интерполяции сферической?

A) сферическая лучше на 3 дБ во всех наборах

B) различие значимо во всех наборах

C) обе дали нулевое качество

D) сферическая чуть хуже (от –0,5 до –0,2 дБ), значимо ни в одном наборе.

Подсказка: смотрите на критерий $2s$.

Шкала самопроверки: 9–10 верных – тема освоена; 7–8 – повторить разделы 6–8; менее 7 – перечитать конспект и вернуться к ЛР 7–8.

Выводы

1. Автокодировщик сжимает вход в латентный вектор; качество определяется размером узкого места относительно числа факторов сцены; PSNR имеет смысл только рядом с эталоном «средняя картинка».
2. Сравнение факторов при фиксированном числе эпох смешивает эффект фактора со скоростью обучения; при изменении объёма выборки нужно сохранять число шагов.
3. Вариационный автокодировщик добавляет к реконструкции KL-член с весом β : латентное пространство становится пригодным для сэмплирования (сэмплы на 8,3–10,5 дБ лучше, чем у обычного), но реконструкция хуже.

4. Схлопывание апостериорного распределения — реальный режим отказа (1 из 5 seed без разогрева); проверяется по значениям для каждого seed, числу активных осей и R^2 .
5. Сильный β (8) сжимает активные оси (2 из 8) и не улучшает интерполяцию и сэмплы; сферическая интерполяция на этих данных не лучше линейной.
6. Латентное пространство автокодировщика лежит в основе Stable Diffusion: диффузия идёт в нём, а качество ограничено реконструкцией.

Источники и дата проверки

1. Kingma D., Welling M. Auto-Encoding Variational Bayes (arXiv:1312.6114, 20.12.2013).
2. Doersch C. Tutorial on Variational Autoencoders (arXiv:1606.05908, 19.06.2016).
3. Burgess C. и др. Understanding disentangling in β -VAE (arXiv:1804.03599, 10.04.2018).
4. van den Oord A. и др. Neural Discrete Representation Learning (arXiv:1711.00937, 02.11.2017).
5. Rombach R. и др. High-Resolution Image Synthesis with Latent Diffusion Models (arXiv:2112.10752, 20.12.2021) — автокодировщик и диффузия в латентном пространстве Stable Diffusion.
6. Журналы выполнения: ЛР 7 — Google Colab, Tesla T4, Python 3.13.15, torch 2.11.0+cu128; ЛР 8 — Engee 26.8.2-Н3, процессор, Python 3.11, torch 2.4.1; 19–20.09.2026.

Публикации проверены по страницам препринтов 19.09.2026 (название, первый автор, дата и содержание аннотации); формулы — стандартные определения; измерения — из журналов выполнения.