

Лекция 7. Генеративно-состязательные сети

Развёрнутый конспект на два академических часа. Дисциплина «Искусственный интеллект в креативных технологиях», магистратура 09.04.02, семестр 1

Паспорт занятия

Параметр	Содержание
Номер и тема	лекция 7 «Генеративно-состязательные сети»
Место в курсе	семестр 1, седьмая лекция из восьми; после диффузионных моделей (лекция 6) показывает второй способ обучения генератора — состязание двух сетей; готовит ЛР 11–13
Длительность	2 академических часа (90 минут чистого времени)
Связанные ЛР	ЛР 11 «Базовая GAN»; ЛР 12 «Устойчивость обучения GAN»; ЛР 13 «Оценка изображений с помощью FID»
Результаты обучения	1) записывать состязательную постановку и объяснять, что оптимизирует каждая сеть на своём шаге; 2) проверять на числах, что даёт оптимальный дискриминатор и почему исходная потеря генератора может не давать градиента; 3) отличать режимы отказа GAN по журналу потерь и по образцам и называть приём стабилизации для каждого; 4) вычислять расстояние FID, объяснять, почему его значение зависит от числа изображений и предобработки; 5) выбирать между GAN и диффузионной моделью по скорости, устойчивости и управляемости
Индикаторы компетенций	ПК-6.1 (протокол эксперимента); ПК-11.1 (безопасная и воспроизводимая работа с программными компонентами ИИ) — через наблюдаемые действия: студент записывает гипотезу и критерий до запуска, считает метрику на серии повторов, сообщает число изображений и версии
Предварительные знания	лекции 1–6; ЛР 1–10

Как читать конспект

Конспект самодостаточен и читается без слайдов. Числа получены реальными запусками в среде Engage (процессор, Python 3.11, PyTorch 2.4.1) 20.09–08.10.2026 и помечены словом «демо». Три источника чисел. Первый — формулы, для которых проверяется теория: оптимальный дискриминатор и значение критерия для одномерных гауссианов (lec07_demo.py, часть dstar). Второй — игрушечная GAN на плоскости, порождающая точки

восьми кластеров на окружности (три seed, четыре режима; части toy и grad): на плоскости отказ можно измерить, а не только показать. Третий — расчёт FID на выборках из гауссовых распределений с известным ответом (часть fid): он показывает смещение метрики по числу изображений. Результаты ЛР 11–12 (малая GAN на синтетических сценах 32×32) вынесены в раздел 7. Квиз из десяти вопросов помещён в конце; ключ — в версии для лектора.

Три сквозных вопроса: **что оптимизирует каждая сеть** (два разных критерия), **как узнать, что обучение идёт плохо** (потери этого не показывают), **чем измерить результат** (FID и его условия).

1. Идея: обучение через соревнование

Как научить модель рисовать реалистичные изображения, если формально описать «реалистичность» трудно? Goodfellow и др. (arXiv:1406.2661) предложили не описывать её, а обучить вторую сеть её различать. **Генератор** G получает случайный вектор $z \sim p_z$ (обычно стандартный гауссов) и создаёт изображение $G(z)$; **дискриминатор** D получает изображение и оценивает вероятность того, что оно настоящее. Генератор выигрывает, когда дискриминатор не отличает подделку; дискриминатор — когда отличает. Соревнование заставляет генератор приближать распределение реальных данных без явной формулы правдоподобия.

Отличие от лекций 5–6. Автокодировщик и диффузионная модель обучаются на **регрессии** — сравнивают выход с известной целью (восстановленное изображение, добавленный шум). У GAN цели нет: качество подделки определяет вторая сеть, которая сама меняется. Отсюда и главная сложность: две цели, которые нужно держать в равновесии.

2. Формулировка и что она означает

Состязательная постановка — минимаксная задача:

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}} [\log D(x)] + \mathbb{E}_{z \sim p_z} [\log(1 - D(G(z)))].$$

Первое слагаемое поощряет дискриминатор за высокую оценку реальных изображений, второе — за низкую оценку сгенерированных. Генератор стремится уменьшить второе слагаемое (в первом его нет).

Оптимальный дискриминатор. При фиксированном генераторе с распределением p_g максимум по D достигается при

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}.$$

Подстановка даёт значение критерия $C(G) = -\log 4 + 2 \text{JSD}(p_{\text{data}} \| p_g)$, где JSD — расхождение Йенсена — Шеннона. Оно минимально и равно $-\log 4 \approx -1,3863$ только при $p_g = p_{\text{data}}$; в этом случае $D^*(x) = 1/2$ при всех x — дискриминатор «не знает», где

настоящее. Вывод авторов: при достаточной ёмкости моделей и идеальной оптимизации генератор восстанавливает распределение данных. На практике условия не выполняются, и обучение сложно.

Порядок обучения. Шаги чередуются: (1) обновить D (один или несколько раз) на смеси реальных и сгенерированных пакетов; (2) обновить G . В начале обучения дискриминатор легко отличает подделки, слагаемое $\log(1 - D(G(z)))$ насыщается, и градиент генератора мал. Поэтому на практике генератор обучают максимизировать $\log D(G(z))$ (**ненасыщающая** потеря): те же положения равновесия, но сильный градиент в начале. Ниже исходную потерю называем «минимаксной», а ненасыщающую — «обычной».

Потеря дискриминатора при идеальном равновесии равна $2 \log 2 \approx 1,386$ (на пакет: $-\log \frac{1}{2} - \log \frac{1}{2}$); отклонение от этого значения не измеряет качество, а показывает, кто из сетей выигрывает в данный момент.

3. Проверка на числах

Оптимальный дискриминатор (демо, часть dstar). Два одномерных распределения: $p_{\text{data}} = \mathcal{N}(0, 1)$ и $p_g = \mathcal{N}(\mu, 1)$. Небольшая сеть (1–32–32–1, tanh) обучалась различать выборки (4000 шагов, 512+512 примеров на шаг) и сравнивалась с формулой D^* на сетке из 401 точки; значение критерия V оценено по 400 000 примеров каждого распределения и сравнено с $-\log 4 + 2 \text{JSD}$, где JSD посчитано интегрированием.

p_g	JSD	V по формуле	V у обученной сети	$\max D - D^* $
$\mathcal{N}(0, 1)$ (совпадает с данными)	0	–1,3863	–1,3863	0,005
$\mathcal{N}(1, 1)$	0,1114	–1,1635	–1,1648	0,015
$\mathcal{N}(3, 1)$	0,5268	–0,3327	–0,3335	0,015

Обученная сеть повторяет D^* с точностью до сотых (наибольшее отклонение 0,015), а значение V совпадает с теорией с точностью до 0,002: формула не просто красива, она описывает то, что делает дискриминатор. Чем дальше p_g от данных, тем больше V — тем «дальше» генератор от равновесия.

Градиент генератора при сильном дискриминаторе (демо, часть grad). Дискриминатор (2–64–64–1) обучался 300 шагов против необученного генератора на восьми кластерах, затем измерялась норма градиента потери генератора по его параметрам для пакета из 1024 векторов.

seed	средняя $D(G(z))$	норма градиента, минимаксная	норма градиента, обычная	отношение
101	0,0018	0,0084	2,95	около 350
102	0,0018	0,0114	4,64	около 410
103	0,0017	0,0064	2,98	около 460

Дискриминатор оценивает подделки как настоящие с вероятностью 0,2 %; при минимаксной потере градиент в 350–460 раз меньше, чем при обычной. **Оговорка.** Это измерение сделано на момент «сильный дискриминатор против необученного генератора»; в игрушечной GAN, обучаемой с самого начала (раздел 4), минимаксная потеря тоже привела к покрытию всех мод: насыщение вредит, когда дискриминатор заметно опережает генератор, а не всегда.


4. Режимы отказа

Режим	Симптом	Причина	Как диагностировать
Коллапс мод	генератор выдаёт узкий набор похожих изображений	генератору выгодно «застрять» на нескольких образцах, которые дискриминатор пока не отвергает	вручную просматривать серию; считать разнообразие (охват, попарные расстояния); следить за ростом FID
Исчезающие градиенты	потеря генератора не уменьшается, изображения не улучшаются	дискриминатор слишком силён	средняя D на подделках близка к 0, на реальных — к 1; норма градиента генератора
Нестабильность	потери колеблются, качество то улучшается, то ухудшается	взаимная адаптация двух сетей; чувствительность к гиперпараметрам	журнал потерь и периодическое сохранение примеров
Переобучение дискриминатора	дискриминатор запоминает обучающие изображения	малый набор данных	разница оценок на обучающих и отложенных данных

Игрушечная GAN (демо, часть toy). Реальное распределение — восемь гауссианов ($\sigma = 0,05$) в вершинах правильного восьмиугольника на окружности радиуса 2. Генератор 2–64–64–2, дискриминатор 2–64–64–1; Adam со скоростью 10^{-3} , $\beta_1 = 0,5$; 3000 шагов, пакет 256, три seed. Мода считается покрытой, если на неё приходится не менее 1 % из 4000 сгенерированных точек; качество — доля точек в пределах 4σ от какой-либо моды.

Режим	Покрыто мод из 8 (seed 101 / 102 / 103)	Качество (101 / 102 / 103)
обычная потеря, 1 шаг D на шаг G	8 / 8 / 8	0,91 / 0,78 / 0,83
минимаксная потеря, 1 шаг D	8 / 8 / 8	0,90 / 0,85 / 0,87
обычная потеря, 5 шагов D на шаг G	4 / 6 / 5	0,91 / 0,92 / 0,92
WGAN-GP, 5 шагов критика	8 / 8 / 8	0,81 / 0,41 / 0,51

Читается так. Перекос в пользу дискриминатора (5 шагов на шаг генератора) даёт **коллапс мод**: покрыто 4–6 мод из 8, при этом качество отдельных точек не хуже — то есть по качеству отдельных образцов коллапс не виден, его показывает только охват. WGAN-GP покрывает все моды, но точки чаще лежат между модами (качество 0,41–0,81): охват и правдоподобие — разные свойства, и метрика должна измерять оба.



Образцы игрушечных GAN, seed 101: слева направо — обычная потеря, минимаксная, обычная с 5 шагами D, WGAN-GP; кружки — моды

Потери — не мера качества. В обычной задаче уменьшение потери означает улучшение. В GAN потеря генератора зависит от оппонента: она может расти при улучшении образцов (дискриминатор тоже учится) и падать при ухудшении. Поэтому в журнал пишут не только потери, но и среднюю оценку D на реальных и поддельных пакетах, и сохраняют образцы через равные интервалы шагов (ЛР 11).

5. Приёмы стабилизации и развитие архитектур

- **Рекомендации DCGAN** (Radford и др., arXiv:1511.06434): свёртки с шагом вместо пулинга, нормализация по пакету в генераторе, LeakyReLU в дискриминаторе; авторы сообщают, что скорость Adam 10^{-3} оказалась слишком высокой (взята $2 \cdot 10^{-4}$), а момент $\beta_1 = 0,9$ вызвал колебания (снижен до 0,5). Это отправная точка ЛР 11.
- **Расстояние Вассерштейна** (Arjovsky и др., arXiv:1701.07875). Вместо JSD используется расстояние Вассерштейна, которое остаётся информативным и тогда, когда распределения почти не пересекаются (JSD в этом случае постоянно, и градиента нет); дискриминатор называют критиком, у него нет сигмоиды, а потеря — разность средних оценок. Требуется ограничить критик липшицевыми функциями.
- **Штраф за градиент** (Gulrajani и др., arXiv:1704.00028) заменяет грубое ограничение весов штрафом за отклонение нормы градиента критика по входу от 1 и стабилизирует обучение (WGAN-GP). Цена — двойное дифференцирование: в игрушечной GAN шаг с критиком в несколько раз дороже.
- **Спектральная нормализация** (Miyato и др., arXiv:1802.05957) — способ ограничить дискриминатор, «вычислительно лёгкий и легко встраиваемый» по формулировке авторов.
- **Два масштаба времени** (Heusel и др., arXiv:1706.08500, TTUR): дискриминатор и генератор обучаются с разными скоростями; в той же работе предложен FID (раздел 6).
- **Сглаживание меток** (Salimans и др., arXiv:1606.03498): целью для реальных изображений берут 0,9, а не 1, чтобы дискриминатор не был чрезмерно уверен.
- **Шум на входе дискриминатора** (Sønderby и др., arXiv:1610.04490): к реальным и поддельным изображениям добавляют шум, убывающий по ходу обучения; это «размывает» распределения и перекрывает их носители.
- **Стилевые генераторы** (Karras и др., arXiv:1812.04948, StyleGAN). Случайный вектор сначала проходит через отображающую сеть, а полученный «стилевой» код

управляет каждым слоем синтеза, что даёт контроль над признаками разного масштаба — от позы до мелких деталей.

Практика: сначала добиваются работоспособности на простых данных, затем добавляют приёмы по одному, каждый раз фиксируя эффект на серии seed, — это и есть план ЛР 12. Выбор приёма зависит от отказа: при сильном дискриминаторе помогают ослабление дискриминатора (TTUR), спектральная нормализация и штраф за градиент; при малом наборе данных — сглаживание меток, шум, регуляризация; универсального средства нет.

6. Оценка: расстояние FID

Идея. Изображения реальной и сгенерированной выборок пропускают через фиксированную сеть-классификатор (Inception) и берут вектор признаков предпоследнего слоя (2048 значений). Каждое множество признаков приближают гауссовым распределением со средним μ и ковариацией Σ . Расстояние Фреше между двумя гауссовыми распределениями и называется **FID** (Heusel и др., arXiv:1706.08500):

$$\text{FID} = \|\mu_r - \mu_g\|^2 + \text{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2}).$$

Меньше — лучше: FID = 0 для совпадающих распределений признаков. Авторы предложили метрику как более согласованную с восприятием сходства, чем Inception Score.


Иллюстрация в одномерном случае. Если признак один, $\text{FID} = (\mu_r - \mu_g)^2 + (\sigma_r - \sigma_g)^2$. Для $\mu_r = 0$, $\sigma_r = 1$ и $\mu_g = 0,5$, $\sigma_g = 1,5$ получаем $0,25 + 0,25 = 0,5$; для $\mu_r = 1$, $\sigma_r = 2$ и $\mu_g = 0$, $\sigma_g = 1$ — $1 + 1 = 2$. Метрика штрафует и сдвиг среднего, и различие разброса, то есть чувствительна и к качеству, и к разнообразию.

Смещение по числу изображений (демо, часть fid). Обе выборки взяты из **одного и того же** гауссова распределения признаков (истинное расстояние равно нулю); вычислялся FID по выборочным μ и Σ , пять повторов, среднее $\pm$ СКО.

Размерность признаков d	$N = 100$	$N = 500$	$N = 2000$	$N = 10\,000$	$N = 50\,000$
64	$30,8 \pm 1,4$	$6,40 \pm 0,15$	$1,62 \pm 0,03$	$0,32 \pm 0,01$	$0,063 \pm 0,002$
512	—	$378,0 \pm 2,1$	$94,1 \pm 0,3$	$18,8 \pm 0,03$	$3,76 \pm 0,02$

Истинное расстояние равно нулю, а полученные значения — от 30,8 до 0,063 при $d = 64$ и до 378 при $d = 512$: у малой выборки оценка ковариации смещена, и смещение растёт с размерностью и убывает с числом изображений (грубо, обратно пропорционально N). Реальные признаки Inception имеют $d = 2048$. Если бы генератор A оценивался по 500 изображениям, а B — по 50 000, по такой таблице выиграл бы B независимо от качества. Это подтверждают Chong и Forsyth (arXiv:1911.07023): значение FID для конечной выборки смещено, причём смещение зависит от модели; они предлагают экстраполяцию к бесконечной выборке. Второй эксперимент: сдвиг среднего на 0,5 по одной оси ($d = 64$,

единичная ковариация, истинное значение 0,25) даёт 22,8 при $N = 100$, 4,73 при 500, 1,39 при 2000 и 0,475 при 10 000: реальное различие тонет в смещении, пока N мало.



Условия корректного применения.

- Число изображений в каждой выборке должно быть достаточно большим и **одинаковым** при сравнении; оно записывается в отчёт. Значения при разном числе изображений сравнивать нельзя.
- Предобработка (размер, интерполяция, диапазон значений, сжатие) и версия сети признаков должны совпадать: Parmar и др. (arXiv:2104.11222) показали, что различия в изменении размера и сжатии заметно меняют FID.
- FID измеряет сходство распределений признаков сети, обученной на определённом наборе; для узкоспециальных изображений (диаграмм, текстур, синтетических сцен) признаки могут быть неинформативны.
- Метрика не заменяет просмотр и не показывает права на данные и корректность содержания.
- Значение — точечная оценка; для сравнения двух моделей повторяют расчёт на нескольких случайных подвыборках и указывают разброс (лекция 1, раздел 6).
- Дополнения: ядерное расстояние Inception (Bińkowski и др., arXiv:1801.01401) не смещено по N ; пары «правдоподобие/охват» — точность и полнота (Kynkäänniemi и др., arXiv:1904.06991) или плотность и охват (Naeem и др., arXiv:2002.09797), которые используются в ЛР 11–12.

7. Что показали ЛР 11–12 (малая GAN на синтетических сценах)

Разделы 3–6 проверяли теорию на плоскости и на гауссианах. В ЛР 11–12 та же логика перенесена на изображения: GAN по рекомендациям DCGAN (генератор из вектора z

размерности 32 строит цветную сцену 32×32 , дискриминатор — три свёртки) обучается на пяти наборах синтетических сцен из ЛР 7 («диск», «диск и прямоугольник», «диск с шумом», «цветной диск», «два диска»). Метрики считаются в пикселях на 1024 сгенерированных и 1024 тестовых сценах: правдоподобие nn_psnr (PSNR до ближайшего настоящего изображения), охват $coverage$ и разнообразие $diversity$ (ЛР 11, раздел 2.3). Каждое сравнение — пять $seed$; эффект признаётся, если разность средних больше двух выборочных стандартных отклонений режима А ($|\Delta| > 2s$). Все обучения выполнены в Engage на процессоре (20.09–08.10.2026).

ЛР 11: что меняет одна настройка базовой GAN (175 обучений по 1500 шагов; в таблице — в скольких наборах из пяти эффект значим и средняя разность по наборам).

Изменение (режим А → В)	nn_psnr : значимо; средняя Δ , дБ	$coverage$: значимо; средняя Δ	$diversity$: значимо; средняя Δ
размерность z : $32 \rightarrow 8$	0 из 5; -0,28	0 из 5; -0,144	0 из 5; +0,037
ширина генератора: $1 \rightarrow 0,5$	3 из 5; -1,75	3 из 5; -0,652	4 из 5; -0,185
скорость обучения: $2 \cdot 10^{-4} \rightarrow 10^{-3}$	5 из 5; +2,27	1 из 5; +0,305	0 из 5; +0,049
момент Adam β_1 : $0,5 \rightarrow 0,9$	5 из 5; -1,75	3 из 5; -0,647	5 из 5; -0,234
нормализация по пакету в G : есть → нет	3 из 5; -2,40	3 из 5; -0,577	5 из 5; -0,320
потеря G : ненасыщающая → минимаксная	0 из 5; +0,35	0 из 5; +0,052	0 из 5; +0,012

Три наблюдения. **Первое:** рекомендации DCGAN о моменте и нормализации подтвердились — $\beta_1 = 0,9$ и отказ от нормализации ухудшают разнообразие во всех пяти наборах. **Второе:** скорость 10^{-3} , которую авторы DCGAN называли слишком высокой, здесь *улучшила* правдоподобие во всех наборах: при 1500 шагах малая сеть со скоростью $2 \cdot 10^{-4}$ просто не успевает доучиться. Рекомендация верна для своих условий (длинное обучение, большие сети), а не вообще — её проверяют на своих данных. **Третье:** минимаксная потеря не дала значимой разницы — в согласии с оговоркой раздела 3: насыщение вредит, когда дискриминатор заметно сильнее генератора, а в сбалансированной базовой GAN этого не происходит. Наконец, разброс между $seed$ велик: у базовой GAN на наборе «два диска» охват колеблется со стандартным отклонением 0,39 при среднем 0,63, поэтому вывод по одному $seed$ может оказаться противоположным выводу по пяти (ЛР 11, раздел 6.4). Потери и здесь не мера качества: в демонстрационном варианте ЛР 11 ($seed$ 101, шаг 1500) потеря генератора у режима А ниже (0,80 против 1,02), а по метрикам лучше режим В (nn_psnr 20,62 против 19,66 дБ, $coverage$ 0,813 против 0,707); у режима А потеря генератора по шагам 100, 300, 700, 1500 равна 1,92; 0,68; 1,05; 0,80 — не убывает, хотя nn_psnr растёт с 13,75 до 19,66 дБ.

ЛР 12: помогает ли приём стабилизации (175 обучений по 1000 шагов). Режим А — та же GAN с одной «неисправностью», режим В — режим А плюс один приём; приём

считается помогшим, если охват или правдоподобие изменились больше $2s$ и больше допуска (0,10 для охвата, 0,5 дБ для nn_psnr) в нужную сторону. В ячейке: охват / правдоподобие; «+» — помог, «-» — навредил, «0» — эффект не найден при пяти seed.

«Неисправность» режима А	сглаживание меток	шум на входе D	спектральная нормализация	WGAN-GP	TTUR	dropout в D
1. скорость $2 \cdot 10^{-3}$, $\beta_1 = 0,9$ (охват $A = 0$)	0 / 0	0 / 0	0 / -	+ / +	0 / 0	0 / 0
2. сильный D (скорость $D \times 10$)	0 / 0	0 / 0	+ / 0	0 / -	+ / 0	0 / 0
3. насыщающая потеря при сильном D	0 / 0	0 / 0	0 / 0	0 / 0	0 / 0	0 / 0
4. 5 шагов D на шаг G	0 / 0	0 / 0	0 / +	0 / -	0 / 0	0 / 0
5. малый набор (256 изображений)	0 / +	0 / 0	+ / 0	+ / 0	+ / +	0 / -

Что видно. **Универсального приёма нет** — ни один не помог во всех пяти режимах; только спектральная нормализация и TTUR ни разу не ухудшили главную метрику. **Приём должен действовать на причину отказа:** при сильном дискриминаторе (режим 2) охват подняли именно приёмы, ограничивающие или замедляющие D , — спектральная нормализация (охват $0,611 \rightarrow 0,967$) и TTUR ($\rightarrow 0,817$); при полном отказе от слишком большого шага (режим 1, охват 0 на всех пяти seed) помог только WGAN-GP, сменивший весь рецепт обучения (охват $\rightarrow 0,557$, nn_psnr +3,07 дБ), а спектральная нормализация там ухудшила правдоподобие на 3,05 дБ. **Нулевой результат не означает «не помогает»:** в режиме 3 часть seed обучается, часть нет, разброс режима А огромен ($s = 0,44$ по охвату), и даже средние приросты TTUR (+0,78) и WGAN-GP (+0,54) не прошли критерий $2s$ — правильная запись «эффект не найден при пяти seed», нужен больший объём повторов. **У приёма есть цена:** в режимах 1–3 обучение с WGAN-GP шло в 2,3–2,7 раза дольше, чем режим А (время измерено при разной загрузке процессора, поэтому это оценка порядка), а в режимах 2 и 4 WGAN-GP снизил правдоподобие. Сглаживание меток, шум на входе дискриминатора и dropout за 1000 шагов почти нигде не дали значимого эффекта.

8. GAN и диффузионные модели: сравнение

Критерий	GAN	Диффузионная модель
Скорость генерации	один вызов генератора	десятки–сотни вызовов сети (уменьшаются ускоренными сэмплерами и дистилляцией)
Устойчивость обучения	чувствительна, требует приёмов (раздел 5)	как правило, устойчивее: обучение — регрессия по шуму
Разнообразие	риск коллапса мод (раздел 4)	обычно выше

Критерий	GAN	Диффузионная модель
Управление текстом	требует дополнительных решений	естественно через условие и управление (лекция 6)
Оценка	FID и родственные метрики; потери не информативны	те же метрики; потеря стабильна, но тоже не мера качества
Типичное применение сегодня	быстрая генерация и преобразование, повышение разрешения, стилевые генераторы для узких областей	универсальные модели «текст → изображение»

Разницу в скорости можно оценить по числу вызовов сети: у GAN один вызов на изображение, у 50-шаговой диффузионной модели — 50, то есть цена примерно в 50 раз выше при сопоставимой стоимости вызова; SD Turbo (лекция 4, 6) сокращает число шагов до одного именно за счёт дистилляции — состязательной (Sauer и др., arXiv:2311.17042). Идеи состязательного обучения остаются в декодерах, повышении разрешения и специализированных генераторах, где нужна скорость и обучающий набор можно контролировать.

9. Что проверить в ЛР 11–13

1. **ЛР 11 «Базовая GAN».** Обучите базовую GAN на синтетических сценах 32×32 (набор из ЛР 7), запишите архитектуру, оптимизатор, скорость, число шагов и seed; сохраняйте образцы через равные интервалы; сравните два режима по трём метрикам на пяти seed.
2. **ЛР 12 «Устойчивость обучения GAN».** Воспроизведите «неисправный» режим (сильный дискриминатор, слишком высокая скорость, малый набор данных, насыщающая потеря) и устраните одним приёмом; для каждого приёма запишите «до и после» на серии seed.
3. **ЛР 13 «Оценка изображений с помощью FID».** Рассчитайте FID между реальной выборкой и выборкой генератора на разных этапах обучения; повторите расчёт на нескольких подвыборках; исследуйте влияние числа изображений и предобработки. Для интерпретации используйте условия из раздела 6.

Численные значения, которые вы получите, зависят от набора, размера выборки и реализации, поэтому сравнивайте только результаты, полученные в одинаковых условиях. Каждая работа выполняется в отдельной папке среды.

10. Типичные заблуждения

- **«Малая потеря генератора означает хорошие изображения».** Потери двух сетей связаны; в демо-обучении потеря генератора и качество образцов вели себя независимо (раздел 7); качество оценивается отдельно.
- **«Дискриминатор должен быть как можно сильнее».** В игрушечной GAN пять шагов D на шаг G дали покрытие 4–6 мод из 8; слишком сильный дискриминатор приводит к исчезающим градиентам и коллапсу.

- «Если качество отдельных образцов хорошее, GAN обучена». В демо коллапс мод не снижает качество отдельных точек (0,91–0,92); охват измеряют отдельно.
- «FID — универсальная оценка качества». Это расстояние между распределениями признаков; при $N = 100$ и $d = 64$ выборки из одного распределения дали 30,8 вместо 0; значение зависит от выборки, предобработки и области.
- «Минимаксная потеря всегда хуже ненасыщающей». Градиент при сильном дискриминаторе был в 350–460 раз меньше, но в демо-обучении с нуля обе потери привели к покрытию всех мод; выбор зависит от того, кто побеждает.
- «GAN устарели». Изменилась область применения, но идеи состязательного обучения используются в декодерах, повышении разрешения, дистилляции SD Turbo и специализированных генераторах.

Итоговый квиз

Десять вопросов идут по порядку разделов лекции, в каждом один верный ответ из четырёх. Подсказка направляет рассуждение, но ответа не называет; ключ с разбором есть в версии для лектора.

Вопрос 1. Что делает генератор в ненасыщающей постановке на своём шаге?

- A) минимизирует $\log(1 - D(G(z)))$
- B) максимизирует $\log D(G(z))$
- C) максимизирует $\log D(x)$ на реальных данных
- D) минимизирует расстояние между $G(z)$ и данными по пикселям.

Подсказка: какое слагаемое содержит G и в какую сторону его сдвигают, чтобы избежать насыщения?

Вопрос 2. Чему равен оптимальный дискриминатор в точке x , если $p_g = p_{\text{data}}$?

- A) 0
- B) 1
- C) 1/2
- D) зависит от x .

Подсказка: подставьте $p_g = p_{\text{data}}$ в $p_{\text{data}}/(p_{\text{data}} + p_g)$.

Вопрос 3. В демо при уверенном дискриминаторе ($D(G(z)) \approx 0,002$) норма градиента генератора равна 0,0084 при минимаксной и 2,95 при обычной потере. Во сколько раз примерно они различаются?

- A) в 3 раза
- B) в 35 раз
- C) в 350 раз
- D) в 3500 раз.

Подсказка: $2,95/0,0084$.

Вопрос 4. В игрушечной GAN при 5 шагах D на шаг G покрыто 4–6 мод из 8, а качество отдельных точек 0,91–0,92. Какой это режим отказа?

- A) исчезающие градиенты

- В) коллапс мод
- С) переобучение дискриминатора
- Д) нормальная работа.

Подсказка: какое свойство выборки нарушено — правдоподобие или разнообразие?

Вопрос 5. Чем критик в WGAN отличается от дискриминатора в исходной постановке?

- А) у критика нет сигмоиды на выходе, потеря — разность средних оценок, нужно ограничение липшицевости
- В) критик выдаёт вероятность настоящего
- С) критик обучается только на подделках
- Д) критик не имеет параметров.

Подсказка: что даёт расстояние Вассерштейна, когда носители распределений не пересекаются?

Вопрос 6. Чему равен FID в одномерном случае для $\mu_r = 1$, $\sigma_r = 2$ и $\mu_g = 0$, $\sigma_g = 1$?

- А) 1
- В) 2
- С) 3
- Д) 5.

Подсказка: $(\mu_r - \mu_g)^2 + (\sigma_r - \sigma_g)^2$.

Вопрос 7. Две выборки из одного распределения ($d = 64$) при $N = 100$ дали FID около 30,8, при $N = 50\,000$ — около 0,06. Что это показывает?

- А) FID зависит от числа изображений, и значения при разном N сравнивать нельзя
- В) распределения на самом деле различаются
- С) FID не может быть меньше 30
- Д) большая выборка портит метрику.

Подсказка: чему равно истинное расстояние между выборками одного распределения?

Вопрос 8. У генератора потеря упала вдвое за последние 500 шагов. Что можно утверждать?

- А) качество выросло вдвое
- В) обучение завершено
- С) само по себе ничего: нужны образцы и метрики
- Д) дискриминатор перестал учиться.

Подсказка: меняется ли оппонент?

Вопрос 9. У диффузионной модели 50 шагов, у GAN один вызов генератора. Во сколько раз примерно больше вызовов сети на изображение у диффузионной модели?

- А) в 5 раз
- В) в 50 раз
- С) в 500 раз
- Д) вызовов поровну.

Подсказка: сколько раз вызывается сеть при 50 шагах?

Вопрос 10. Охват (coverage) сгенерированной выборки равен 0. Какой вывод корректен?

А) все изображения плохие

В) ни одно сгенерированное изображение не попало в окрестность настоящих; при этом правдоподобие каждого нужно смотреть отдельно

С) дискриминатор победил

Д) выборка слишком большая.

Подсказка: что измеряет охват — окрестности настоящих или качество отдельных картинок?

Шкала самопроверки: 9–10 верных — тема освоена; 7–8 — повторить разделы 4 и 6; менее 7 — перечитать конспект и вернуться к ЛР 11–13.

Выводы

1. GAN обучается состязанием двух сетей с разными целями; при оптимальном дискриминаторе критерий равен $-\log 4 + 2 \text{JSD}$; в демо обученная сеть повторила D^* с точностью до сотых, а V — с точностью до 0,002.
2. Исходная минимаксная потеря даёт малый градиент при сильном дискриминаторе (в 350–460 раз меньше обычной в демо); на практике генератор обучают ненасыщающей потерей.
3. Потеря — не мера качества; отказ виден по образцам, оценке D на реальных и поддельных пакетах и по охвату; коллапс мод не снижает качество отдельных образцов.
4. Приёмы стабилизации (WGAN-GP, спектральная нормализация, TTUR, сглаживание, шум) подбирают по отказу и проверяют на серии seed.
5. FID зависит от числа изображений, предобработки и версии сети признаков: при $N = 100$ и $d = 64$ выборки из одного распределения дали 30,8 вместо 0.
6. GAN быстры (один вызов), но требовательны к настройке; диффузионные модели устойчивее и лучше управляются текстом.

Источники и дата проверки

1. Generative Adversarial Networks — Goodfellow I. и др.; arXiv:1406.2661 от 10.06.2014.
2. Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks — Radford A., Metz L., Chintala S.; arXiv:1511.06434 от 19.11.2015.
3. Wasserstein GAN — Arjovsky M., Chintala S., Bottou L.; arXiv:1701.07875 от 26.01.2017.
4. Improved Training of Wasserstein GANs — Gulrajani I. и др.; arXiv:1704.00028 от 31.03.2017.
5. Spectral Normalization for Generative Adversarial Networks — Miyato T. и др.; arXiv:1802.05957 от 16.02.2018.
6. GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium — Heusel M. и др.; arXiv:1706.08500 от 26.06.2017.

7. Improved Techniques for Training GANs — Salimans T. и др.; arXiv:1606.03498 от 10.06.2016.
8. Amortised MAP Inference for Image Super-resolution — Sønderby C. K. и др.; arXiv:1610.04490 от 14.10.2016 (раздел 3.2.1: шум на входе дискриминатора).
9. A Style-Based Generator Architecture for Generative Adversarial Networks — Karras T. и др.; arXiv:1812.04948 от 12.12.2018.
10. Effectively Unbiased FID and Inception Score and where to find them — Chong M. J., Forsyth D.; arXiv:1911.07023 от 16.11.2019.
11. On Aliased Resizing and Surprising Subtleties in GAN Evaluation — Parmar G. и др.; arXiv:2104.11222 от 22.04.2021.
12. Demystifying MMD GANs — Bińkowski M. и др.; arXiv:1801.01401 от 04.01.2018.
13. Improved Precision and Recall Metric for Assessing Generative Models — Kynkäänniemi T. и др.; arXiv:1904.06991 от 15.04.2019.
14. Reliable Fidelity and Diversity Metrics for Generative Models — Naeem M. F. и др.; arXiv:2002.09797 от 23.02.2020.
15. Adversarial Diffusion Distillation — Sauer A. и др.; arXiv:2311.17042 от 28.11.2023.
16. Журнал выполнения: демонстрации `lec07_demo.py` (20.09.2026) и полные прогоны ЛР 11–12 (20.09–08.10.2026) — Engee 26.8.2-Н3 и 26.9.2-Н4, процессор, Python 3.11, torch 2.4.1+cu121.

Публикации проверены по записям arXiv 20.09.2026 (название, авторы, дата, аннотация); формулы — по работам Goodfellow и др. (2014) и Heusel и др. (2017); значения скорости и момента в DCGAN — по тексту статьи Radford и др.