



ИИ В КРЕАТИВНЫХ ТЕХНОЛОГИЯХ

ГЕНЕРАЦИЯ ИЗОБРАЖЕНИЙ


Модели, конвейер text-to-image и параметры. Лекция 4 ·
магистратура 09.04.02 · семестр 1

ЛР 5-6 · SD TURBO В COLAB



ЦЕЛИ И МАРШРУТ

Что вы сможете после лекции и как мы к этому идём



ПОСЛЕ ЛЕКЦИИ ВЫ СМОЖЕТЕ

- назвать семейства порождающих моделей изображений
- описать компоненты конвейера text-to-image
- объяснить действие seed, шагов, guidance, размера, запроса и языка
- записать паспорт запуска и повторить результат
- спланировать эксперимент с допуском до запуска


МАРШРУТ, 90 МИНУТ

- **7** — задача и три идеи
- **8** — семейства моделей
- **10** — диффузия и латентное пространство
- **12** — конвейер по компонентам
- **12** — seed, шум, воспроизводимость
- **10** — шаги и дистилляция
- **12** — масштаб управления
- **11** — размер, запрос, язык
- **8** — эксперимент, квиз, итоги



ЗАДАЧА: ОПИСАНИЕ → ИЗОБРАЖЕНИЕ

Соответствие неоднозначно, а перебор пикселей невозможен



1. ДАННЫЕ

пары «изображение — описание»
в большом объёме

2. ИТЕРАЦИИ

результат строится из шума шаг
за шагом

3. ЛАТЕНТНОЕ ПРОСТРАНСТВО

вычисления в сжатом
представлении, а не в пикселях

ДВЕ ТРУДНОСТИ

- одной фразе отвечает **множество** допустимых изображений
- пространство изображений огромно: перебор невозможен


ОСТАНОВКА 1

Текст и сеть одни и те же. **Что должно отличаться**, чтобы получились разные изображения?



ЧЕТЫРЕ СЕМЕЙСТВА МОДЕЛЕЙ

Какая модель как порождает изображение




Семейство	Как порождает	Сильные стороны	Ограничения
Вариационные автокодировщики (лекция 5)	декодируют точку латентного пространства	быстро, удобное латентное пространство	результаты часто размыты
Генеративно-состязательные сети (лекция 7)	шум → изображение за один проход	очень быстро, высокая резкость	неустойчивое обучение, потеря разнообразия
Диффузионные модели (лекция 6)	многошаговое удаление шума	качество и разнообразие, устойчивое обучение	много шагов при генерации
Авторегрессионные модели (обзорно)	последовательность фрагментов	единая архитектура для разных модальностей	длинные последовательности






Основа систем «текст → изображение»: **диффузия в латентном пространстве** — этот конвейер мы разберём по частям.

ДИФфуЗИЯ: ШУМ И ОБРАТНЫЙ ПУТЬ

Прямой процесс добавляет шум, обратный — шаг за шагом убирает



данные



шум

прямой процесс: добавление шума → обратный процесс: модель шаг за шагом удаляет шум ←

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$


ОБРАТНЫЙ ПУТЬ

сеть оценивает шум по состоянию, номеру шага и тексту; планировщик делает шаг от t к $t - 1$



ЛАТЕНТНОЕ ПРОСТРАНСТВО

Диффузия идёт не в пикселях, а в сжатом тензоре



$$\frac{3 \cdot 512 \cdot 512}{4 \cdot 64 \cdot 64} = \frac{786\,432}{16\,384} = 48$$

SD TURBO (ПРОГОН ЛЕКЦИИ)


- латентных каналов: **4**
- сторона меньше в **8** раз
- кадр $512 \times 512 \rightarrow$ тензор $4 \times 64 \times 64$

Меньше значений — быстрее шаг. Отсюда 0,3 с на изображение в ЛР 5–6.



КОНВЕЙЕР TEXT-TO-IMAGE

Кодировщик текста, шум, сеть, планировщик, декодер



КОДИРОВЩИК ТЕКСТА

CLIPTextModel 340,4 млн
парам. до 77 токенов

НАЧАЛЬНЫЙ ШУМ

тензор $4 \times 64 \times 64$ задаётся seed

СЕТЬ ШУМОПОДАВЛЕНИЯ

UNet2DConditionModel 865,9
млн парам. повторяется N
раз

ДЕКОДЕР VAE


83,7 млн парам. тензор →
пиксели

Планировщик — EulerDiscreteScheduler, шаги «trailing»: на каждом шаге вычитает долю оценённого шума.

Изображение = Decode(Step(... Step(шум, $\hat{\epsilon}(x, t, \text{текст})$...)), N раз). Для SD Turbo N — от 1 до 4.

КАРТА ПАРАМЕТРОВ

Каждый параметр действует на один компонент конвейера




Параметр	Что меняет	Как влияет	Типичный риск
Seed	начальный шум	какой из вариантов получится	сравнение запросов на одном seed
Число шагов	число итераций	больше деталей, больше времени	шаги без выигрыша
Guidance	вес текстового условия	сильнее следование запросу	артефакты, вне режима модели
Размер кадра	латентный тензор	«родной» размер лучше	искажения композиции
Запрос, язык	вход кодировщика	содержание и стиль	ожидание точного счёта
Отрицательный запрос	вторая ветвь управления	отдаляет от описанного	не действует при guidance ≤ 1



СОВРЕМЕННЫЕ АРХИТЕКТУРЫ

Трансформеры и «поток» вместо шума вытесняют U-Net



ТРАНСФОРМЕР ВМЕСТО U-NET

сеть шумоподавления на трансформере (Peebles, Xie, 2022)

ОБУЧЕНИЕ ПО ПОТОКУ

вместо оценки шума — вектор потока (Lipman и др., 2022)

STABLE DIFFUSION 3


трансформерная сеть и выпрямленный поток (Esser и др., 2024)

Интерфейс конвейера не меняется. Параметры лекции **переносятся с оговорками**: у каждой модели свои рекомендованные шаги, guidance и размер — они записаны в её карточке.




SEED И НАЧАЛЬНЫЙ ШУМ


Разные seed — разные изображения, один seed — один шум




seed 101




seed 102



seed 103



seed 104



разные seed → разный начальный шум → разные изображения (PSNR между парами 9–15 дБ)

ПРОГОН ЛЕКЦИИ


- 4 seed, один бриф
- PSNR между парами **9,6–10,7 дБ**
- допуск «совпало» — **40 дБ**

Seed фиксирует шум **только** при неизменных генераторе и типе данных. Что ещё влияет — на следующем слайде.

ВОСПРОИЗВОДИМОСТЬ: ЛР 5

Шесть условий сравнения, 30 вариантов, два сеанса

Условие (один seed)	PSNR A и B, дБ	Вердикт
повтор запуска	∞ (SHA-256 совпал)	идентично
seed и seed + 1	9–15	различно
генератор CPU и GPU	9–15	различно
float16 и float32	7–16	различно
...с одинаковым шумом	37–51	близко
PNG и JPEG (качество 90)	28–37	потеря
одиночный запуск и пакет	47–51	близко



ОСТАНОВКА 2

Один seed. Вычисления **float16** → **float32**. Изображение совпадёт?


ПРИЧИНА

randn выдаёт **разные числа** для float16 и float32: различается шум, а не точность сети.



ПАСПОРТ ЗАПУСКА

Что записать, чтобы результат можно было повторить



ПРАВИЛА ВОСПРОИЗВОДИМОСТИ


- генератор **на CPU**: числа CPU и GPU разные
- Generator хранит **состояние**: создавайте новый на каждый запуск
- ошибка ЛР 5: общий генератор → второй запуск отличался (**11,14 дБ**)
- между платформами SHA-256 не ожидается

ПАСПОРТ ЗАПУСКА

- модель и **ревизия**, лицензия
- seed, устройство генератора
- тип вычислений, планировщик
- шаги, guidance, размер
- версии библиотек, устройство
- SHA-256 результата

ШАГИ И ДИСТИЛЛЯЦИЯ

SD Turbo рассчитана на 1–4 шага



SD TURBO

- дистиллированная версия **Stable Diffusion 2.1**
- метод — состязательная диффузионная дистилляция
- **1–4 шага**, рекомендован один
- размер **512×512**, guidance **0,0**
- текст не выводит, люди и лица — нестабильно

ПРИМЕР ИЗ ЖИЗНИ: СКУЛЬПТОР


Ситуация. Черновой слой — фигура уже узнаётся, тонкие слои добавляют детали.

Соответствие. Шаги удаления шума; у SD Turbo достаточно одного «чернового» шага.


Граница. Модель не видит цель заранее: больше шагов не значит ближе к запросу.

ШАГИ В ЦИФРАХ: ЛР 6


Бриф 1, пять seed, 512×512: детали и время растут, CLIP — нет




энергия границ




контраст



сходство CLIP



время, с




Границы **×2**, контраст **+44 %**, время **×1,9**; сходство CLIP **в пределах разброса**. «Резче» не значит «лучше».




МАСШТАБ УПРАВЛЕНИЯ

Классификаторо-свободное управление: две оценки шума и вес s



$$\tilde{\epsilon} = \epsilon_{\theta}(x_t, \emptyset) + s (\epsilon_{\theta}(x_t, c) - \epsilon_{\theta}(x_t, \emptyset))$$

оценки шума: движение от «без текста» к «с текстом» и дальше



СВЯЗЬ С БИБЛИОТЕКАМИ


$$s = 1 + w$$

- при $s = 1$ — условная оценка
- при $s > 1$ — усиление разницы «с текстом» и «без»
- w из статьи и s из библиотек **не равны**



GUIDANCE у SD TURBO

Значения от 0 до 1 не влияют: управление выключено



GUIDANCE = 1,0

Совпало с 0,0 **побитово**.
do_classifier_free_guidance = False

GUIDANCE = 3,0

CFG включён, PSNR **11,6 дБ**; границы
и контраст ↑, время +0,07 с

ОТРИЦАТЕЛЬНЫЙ ЗАПРОС

при 0,0 — **не действует** (SHA-256
совпал); при 3,0 — PSNR 11,5 дБ

ОСТАНОВКА 3

guidance = **1,0** вместо 0,0. Что изменится?



ПРИМЕР ИЗ ЖИЗНИ: ГРОМКОСТЬ

Чуть громче — разборчивее, слишком громко — хрип. Но
guidance — **не громкость**: он усиливает разность двух оценок
шума.



РАЗМЕР КАДРА

У модели есть «родной» размер: 512×512



ЧТО ВИДНО


- 384 быстрее на **34 %**
- 768 медленнее в **2,2** раза
- метрики изображения меняются **непоследовательно**
- вывод по размеру — по глазам и допуску

Время — бриф 1, одна серия seed; в ЛР 6 значения по вариантам различаются в пределах десятых долей секунды.



ЗАПРОС И ЯЗЫК: ЛР 6

Структура запроса важнее размера; русский запрос теряет 18 пунктов



ОСТАНОВКА 4

Почему **русский запрос** даёт -17,6, а **размер** — почти ноль?

ПРИМЕР: ПОСРЕДНИК


Через посредника с плохим языком теряются тонкие требования. Но кодировщик не «переводит» — он строит векторы.

Сходство CLIP всегда считается относительно английского брифа — единого эталона для обоих режимов.



КАК ПИСАТЬ ЗАПРОС

Пять частей, порядок слов и ограничения



СУБЪЕКТ

кто или что

КОМПОЗИЦИЯ

действие, план,
ракурс

СРЕДА

место, время, свет

СТИЛЬ И МАТЕРИАЛ

жанр, техника

ОГРАНИЧЕНИЯ

палитра, «без текста»

ЧТО НЕ СТОИТ ОЖИДАТЬ


- точный **счёт** объектов
- читаемый **текст** на изображении
- сложные пространственные отношения

ЕСЛИ ЗАПРОС ИСЧЕРПАН

- не удлинять фразу
- пространственное управление и дообучение (лекция 6)
- проверка результата после генерации

ПЛАН ЭКСПЕРИМЕНТА

Гипотеза, один фактор, серия seed, допуск до запуска



1 **Гипотеза** — до запуска

2 **Один фактор**, остальное фиксируем

3 **Серия seed**, не менее пяти, одинаковая для A и B

4 **Метрики**: CLIP, границы, контраст, время

5 **Допуск** — до запуска

6 **Вывод**: Δ , s , $|\Delta| > 2s$ и допуск


Допуск (образец)	CLIP	Границы, контраст	Время
записывается до запуска	$\pm 1,0$	$\pm 10 \%$	$\pm 20 \%$

Значимость по $2s$ отвечает «есть ли эффект», допуск — «нужен ли он» (лекция 3).



ДЕМО ЛР 6: ЗНАЧИМОСТЬ И ДОПУСК

Шаги 1 → 4, бриф 1: где критерий $2s$ и допуск согласны




Метрика	A (1 шаг)	s	B (4 шага)	Δ	$ \Delta /s$	Допуск
сходство CLIP	30,80	1,39	30,29	-0,50	0,36	в допуске
энергия границ	0,0457	0,0069	0,0920	+0,0463	6,68	за допуском
контраст	0,192	0,023	0,278	+0,086	3,79	за допуском
время, с	0,285	0,003	0,527	+0,241	87,8	за допуском

Четыре шага — больше деталей и контраста за большее время; **выигрыша по сходству с брифом нет**. Стоит ли это для афиши — данных недостаточно: нужна экспертная оценка.

ЛОКАЛЬНЫЙ ЗАПУСК, API И ЛИЦЕНЗИЯ

Что контролирует пользователь и что оставлено поставщику



	Локальный запуск	Программный интерфейс
Версия модели	фиксируем ревизию весов	определяет поставщик
Данные	остаются у вас	передаются внешнему сервису
Ресурсы	нужно оборудование (в ЛР — Colab T4)	не нужны
Лицензия	проверяется до использования	условия поставщика


ЛИЦЕНЗИЯ SD TURBO (5.07.2024)

Коммерческое использование — при доходе **менее 1 млн долларов**; регистрация; уведомление и «Powered by Stability AI» при распространении.



ТИПИЧНЫЕ ЗАБЛУЖДЕНИЯ

Шесть утверждений, которые звучат убедительно




Заблуждение	Что на самом деле
Больше шагов — всегда лучше	1 → 4: детали и время растут, сходство с запросом нет
Один seed — то же изображение везде	CPU и GPU, float16 и float32 дают разные изображения
guidance = 1 чуть усиливает запрос	у SD Turbo значения от 0 до 1 не влияют
Отрицательный запрос — надёжный фильтр	при guidance ≤ 1 не действует, иначе лишь смещает
Русский запрос работает как английский	сходство с брифом ниже в среднем на 17,6
Метрика выросла — значит, лучше	энергия границ растёт и от шума: нужен допуск и просмотр



ЧТО ДЕЛАТЬ В ЛР 5–6

Каждая работа — в новом блокноте Colab



ЛР 5 · ЗАПУСК И ВОСПРОИЗВОДИМОСТЬ

- SD Turbo по закреплённой ревизии
- result.png и manifest.json
- шесть условий сравнения A и B
- ошибка общего генератора

ЛР 6 · ПАРАМЕТРЫ ГЕНЕРАЦИИ


- один из шести факторов
- серия из 5 seed, таблица метрик
- допуск — до запуска
- сравнительный лист comparison.png

Новая работа — новая вкладка и новый блокнот.



КВИЗ: ВОПРОСЫ 1–5

Один верный ответ из четырёх; подсказки — в конспекте



1. Какое семейство порождает изображение многошаговым удалением шума?

A) диффузионные модели

B) вариационные автокодировщики

C) генеративно-состязательные сети

D) авторегрессионные модели

2. Во сколько раз $4 \times 64 \times 64$ меньше, чем $3 \times 512 \times 512$?

A) в 6

B) в 12

C) в 24

D) в 48

3. Что задаёт seed при прочих равных?

A) веса модели

B) начальный шум

C) текст запроса

D) число шагов

4. float16 и float32, один seed — картинки разные. Причина?

A) хуже свёртки в float16

B) другие веса

C) randn выдаёт разный шум

D) JPEG сжимает по-разному

5. Что даёт формула guidance при $s = 1$?

A) условную оценку шума

B) безусловную оценку


C) нулевой вектор

D) удвоенную разность



КВИЗ: ВОПРОСЫ 6–10

Один верный ответ из четырёх; подсказки — в конспекте



6. Как связаны w из статьи и s из библиотек?

A) $s = w$

B) $s = w^2$

C) $s = 1 + w$

D) $s = 1 - w$

7. SD Turbo, guidance 1,0 вместо 0,0 (ЛР 6)?

A) совпало побитово

B) стало ярче

C) время $\times 2$

D) ошибка загрузки

8. Шаги $1 \rightarrow 4$, бриф 1 (ЛР 6): что верно?

A) CLIP значимо вырос

B) границы $\times 2$, CLIP в допуске

C) время не изменилось

D) контраст упал

9. Русский запрос вместо английского: сходство CLIP (среднее)?

A) не изменилось

B) +6 пунктов

C) -18 пунктов

D) +18 пунктов

10. Почему сравнение запросов на одном seed ненадёжно?

A) seed меняет веса

B) формулировки дают одно и то же


C) время зависит от seed

D) эффект зависит от шума: нужна серия seed

ИТОГИ

Шесть вещей, которые нужно унести с лекции

- конвейер: кодировщик текста, шум, сеть, планировщик, декодер; латентное пространство **в 48 раз** меньше
- воспроизводимость — это **паспорт запуска**; между платформами она не гарантируется
- шаги: детали и время растут, сходство с запросом у SD Turbo — нет
- guidance работает при $s > 1$; у SD Turbo рекомендовано 0,0
- структурированный запрос **+6,1**, русский **-17,6** пункта CLIP
- вывод — по серии seed, критерию 2s и **допуску до запуска**





ИСТОЧНИКИ

Названия, первые авторы и даты проверены 19.09.2026

- Rombach R. и др. High-Resolution Image Synthesis with Latent Diffusion Models. arXiv:2112.10752, 2021
- Ho J. и др. Denoising Diffusion Probabilistic Models. arXiv:2006.11239, 2020
- Song J. и др. Denoising Diffusion Implicit Models. arXiv:2010.02502, 2020
- Ho J., Salimans T. Classifier-Free Diffusion Guidance. arXiv:2207.12598, 2022
- Sauer A. и др. Adversarial Diffusion Distillation. arXiv:2311.17042, 2023
- Peebles W., Xie S. Scalable Diffusion Models with Transformers. arXiv:2212.09748, 2022
- Lipman Y. и др. Flow Matching for Generative Modeling. arXiv:2210.02747, 2022
- Esser P. и др. Scaling Rectified Flow Transformers for High-Resolution Image Synthesis. arXiv:2403.03206, 2024
- Radford A. и др. Learning Transferable Visual Models From Natural Language Supervision. arXiv:2103.00020, 2021
- Карточка модели stabilityai/sd-turbo и LICENSE.md; документация Diffusers и PyTorch «Reproducibility»
- Журналы ЛР 5–6 и прогона лекции: Google Colab, Tesla T4, 19.09.2026

