


АВТО- КОДИРОВЩИКИ

Латентное пространство, вариационные модели и интерполяция. Лекция 5 · магистратура 09.04.02 · семестр 1


ЛР 7-8 · АВТОКОДИРОВЩИКИ





ЦЕЛИ И МАРШРУТ

Что вы сможете после лекции и как мы к этому идём



ПОСЛЕ ЛЕКЦИИ ВЫ СМОЖЕТЕ

- описать автокодировщик и роль **узкого места**
- объяснить, зачем вариационной модели нужен **KL-член**
- выбрать размер вектора и вес β **по измерениям**
- построить сэмплы и **интерполяцию** и оценить их
- узнать **схлопывание** апостериорного распределения


МАРШРУТ, 90 МИНУТ

- **6** — сжатие и порождение
- **12** — автокодировщик и узкое место
- **10** — размер вектора и эталон
- **6** — шумоподавляющий автокодировщик
- **14** — вариационный автокодировщик
- **12** — вес β и схлопывание
- **12** — сэмплирование и интерполяция
- **8** — дискретные коды, Stable Diffusion
- **10** — заблуждения, ЛР 7–8, квиз



СЖАТИЕ И ПОРОЖДЕНИЕ

Один приём — короткий вектор вместо тысяч пикселей



СЖАТИЕ

записать изображение малым числом чисел и восстановить

ПОРОЖДЕНИЕ

получить новое изображение, которого не было в наборе

ОБЩИЙ ПРИЁМ

латентный вектор: короткое описание сцены

СЦЕНА ИЗ ЛР 7

- изображение $3 \times 32 \times 32 = \mathbf{3072}$ числа
- порождено **тремя** факторами: положение x , y и радиус диска


ОСТАНОВКА 1

Сколько чисел нужно вектору? Почему **500 чисел** не заставят сеть найти три?



АВТОКОДИРОВЩИК

Кодировщик, узкое место, декодировщик; вход служит и целью



вход x : $3 \times 32 \times 32 = 3072$ числа

выход $\hat{x}$: 3072 числа




$$\mathcal{L}_{AE} = \frac{1}{n} \|x - D(E(x))\|^2$$

Вход служит и целью: **обучение без учителя**. Без узкого места сеть может просто копировать вход.

СЕТЬ ИЗ ЛР 7

Три свёртки, вектор из d чисел, три транспонированные свёртки



Часть	Слои	Размер
Кодировщик	3 свёртки 4×4, шаг 2 (3→16→32→64)	вход 3×32×32
Латентный вектор	линейный слой	d чисел (8 в режиме A)
Декодировщик	линейный слой, 3 транспонированные свёртки, сигмоида	выход 3×32×32
Параметры	d = 8: 101,0 тыс. ; d = 2: 88,7 тыс.	полносвязная сеть: 1580,6 тыс.

СКОРОСТЬ ОБУЧЕНИЯ

≈2 с на T4 против ≈325 с на процессоре ноутбука (пробный запуск)


ОЦЕНКА

PSNR на **1024 тестовых** сценах, серия из **5 seed**



ЭТАЛОН: СРЕДНЯЯ КАРТИНКА

PSNR без эталона ничего не говорит



СРЕДНЯЯ КАРТИНКА

17,2 дБ

эталон: один и тот же ответ на любой вход

D = 2

23,2 дБ

выигрыш **6,0 дБ**

D = 8

26,0 дБ


выигрыш **8,8 дБ**

Набор «диск»: большой однородный фон. Тривиальный ответ уже даёт **17,2 дБ**, поэтому «23 дБ» — не высокое значение, а выигрыш **6 дБ** над эталоном.




РАЗМЕР ВЕКТОРА И ЧИСЛО ФАКТОРОВ

Качество растёт до $d = 3-4$ и дальше не растёт



ПРАВИЛО


- у диска **3** фактора
- $d = 2$ не вмещает радиус
- $d = 4$ и $d = 8$ различаются **меньше**, чем seed
- нужное d — из **развёртки**, а не из одного значения






КАК ВЫГЛЯДИТ ПОТЕРЯ

Оригиналы, $d = 8$ и $d = 2$ на одних и тех же сценах



Строки сверху вниз: оригиналы, $d = 8$, $d = 2$ (seed 101, тест). Снимок ячейки Colab (ЛР 7).



ОСТАНОВКА 2



При $d = 2$ диск на месте, но **всех дисков один размер**. Почему? Что изменить?

Пример из жизни: **чемодан на неделю** — влезает только необходимое, а слишком большой чемодан не заставляет выбирать. Граница аналогии: набор «необходимого» определяет ошибка реконструкции.



ЧТО МЕНЯЕТ ФАКТОР

ЛР 7: 30 вариантов, пять наборов сцен, шесть факторов






ЧТО ВИДНО

- узкое горлышко вредит **надёжно**
- рост d **не окупается**
- полносвязная сеть: **15,6×** параметров, разрыв train – test больше
- L1 — вопрос **сходимости**

СХОДИМОСТЬ И ЧИСЛО ШАГОВ

Два фактора, которые измеряют не то, что кажется




Сравнение при **фиксированной** эпохе смешивает эффект фактора со скоростью обучения: держите число **шагов** одинаковым и проверяйте контрольным прогоном.



ШУМОПОДАВЛЯЮЩИЙ АВТОКОДИРОВЩИК

Вход искажается, цель — чистое изображение



ШУМОПОДАВЛЯЮЩЕЕ ОБУЧЕНИЕ

- вход: изображение + шум $\sigma = 0,2$
- цель: **чистое** изображение
- набор «диск»: $22,5 \rightarrow 25,6$ дБ (+3,1)
- $|\Delta|/s = 0,8$: критерий **2s не выполнен** (разброс режима A 3,7 дБ)
- по пяти наборам: +1,1...+3,1 дБ, значимо в **2 из 5**

ПРИМЕР ИЗ ЖИЗНИ: РЕСТАВРАТОР


Ситуация. Реставратор восстанавливает фреску по повреждённому фрагменту: убирает царапины, а не копирует их.

Соответствие. Сеть учится восстанавливать чистую цель по повреждённому входу, поэтому шум не попадает в выход.


Граница. Сеть не знает эпохи: она восстанавливает то, что часто встречалось в данных, и может «дорисовать» несуществующее.

ЧЕГО НЕ ХВАТАЕТ АВТОКОДИРОВЩИКУ

Нет гарантии, что декодировщик работает вне закодированных точек



обычный автокодировщик



вариационный




иллюстрация (не данные): закодированные точки и область $N(0, I)$ — штриховая окружность радиуса 2σ

ПРОБЛЕМА



- обучение не задаёт, **где** лежат векторы
- вне закодированных точек декодировщик **не обучался**
- нужно согласовать пространство с $N(0, I)$

Иллюстрация схематична; реальные значения разброса μ — в ЛР 8 (следующие слайды).



ВАРИАЦИОННЫЙ АВТОКОДИРОВЩИК

Кодировщик выдаёт распределение; KL тянет его к $N(0, I)$




$$\mathcal{L} = \|x - \hat{x}\|^2 + \beta KL(q(z|x) \parallel \mathcal{N}(0, I))$$

$$z = \mu + \sigma \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$



ПОТЕРИ И KL

Что тянет в разные стороны и как посчитать KL



$$KL = -\frac{1}{2} \sum_j (1 + \log \sigma_j^2 - \mu_j^2 - \sigma_j^2)$$

ПРОВЕРКА СЧЁТА

$$\mu = 0,5, \sigma = 1 : KL = \frac{\mu^2}{2} = 0,125$$

ДВЕ СИЛЫ

- **реконструкция** — по z можно восстановить x
- **KL** — распределения тянутся к $N(0, I)$
- β — цена информации в векторе



ОСТАНОВКА 3

Что будет, если убрать **KL**? А если убрать **реконструкцию**?



СЭМПЛЫ: AE И VAE

Из обычного автокодировщика сэмплировать из $N(0, I)$ нельзя





Строки сверху вниз: сэмплы AE, сэмплы VAE ($\beta = 1$), путь между сценами при $\beta = 1$ и $\beta = 8$. Снимок листа сравнения в Engage (ЛР 8).

Разброс μ по осям: AE — **2,0–4,9**, VAE — **0,2–1,0**. Сэмпл из $N(0, I)$: **12,9** → **23,3 дБ** (набор «диск»).



ВЕС В: ЦЕНА ИНФОРМАЦИИ

$\beta = 1 \rightarrow 8$ на наборе «диск»: активны 2 оси из 8



ИТОГ В = 8



- реконструкция **-3,8 дБ**
- интерполяция и сэмплы **не лучше**
- оси: **7 $\rightarrow$ 2**

Показатель	$\beta = 1$	$\beta = 8$	Δ	$ \Delta /s$	2s
реконструкция, дБ	26,37	22,53	-3,84	6,26	да
интерполяция, дБ	22,55	21,90	-0,65	1,34	нет



СХЛОПЫВАНИЕ АПОСТЕРИОРНОГО РАСПРЕДЕЛЕНИЯ

Один запуск из пяти дал среднюю картинку



КАК УЗНАТЬ


- PSNR = **эталону** (17,2 дБ)
- R^2 факторов ≈ 0
- большой **разброс** между seed
- лечится **разогревом KL**: 0 из 5

Среднее **$24,2 \pm 4,0$ дБ** скрывает один схлопнувшийся запуск: смотрите на **каждый seed**.



СЭМПЛИРОВАНИЕ И ИНТЕРПОЛЯЦИЯ

Как идти по латентному пространству



ЛИНЕЙНАЯ

$$z_t = (1 - t)z_a + tz_b$$

СФЕРИЧЕСКАЯ

$$z_t = \frac{\sin((1 - t)\Omega)}{\sin \Omega} z_a + \frac{\sin(t\Omega)}{\sin \Omega} z_b$$

СЭМПЛИРОВАНИЕ

- $z \sim N(0, \tau^2 I)$, затем $\hat{x} = D(z)$
- $\tau = 1$ — априорное распределение
- $\tau = 2$ — вне области обучения


ОЦЕНКА ИНТЕРПОЛЯЦИИ

- точки пути **$t = 0,25; 0,5; 0,75$**
- эталон — сцена по **средним факторам** пары
- у реальных изображений эталона **нет**




ИНТЕРПОЛЯЦИЯ: ПИКСЕЛИ И ПАРАМЕТРЫ


Смешать пиксели — не то же самое, что усреднить параметры




сцена А



смещение пикселей
50 % / 50 %



среднее по параметрам
(положение, радиус)



сцена В




иллюстрация построена кодом, модель не использовалась

ПРИМЕР: ДВА ЭСКИЗА

50 % прозрачности — **двойной контур**; среднее по параметрам — **новый чёткий** вариант.




ГРАНИЦА АНАЛОГИИ

Оси не обязаны совпадать с параметрами: R^2 факторов **0,90** у диска и **0,57** у цветного диска.



ИНТЕРПОЛЯЦИЯ И ТЕМПЕРАТУРА В ЦИФРАХ

Сферическая — не лучше линейной; $\tau = 2$ ухудшает сэмплы





АЕ и VAE интерполируют **одинаково** (22,63 и 22,53 дБ): KL-член нужен для **порождения**, а не для интерполяции между известными точками.



ОСТАНОВКА 4: ПУТИ ИНТЕРПОЛЯЦИИ

$\beta = 1$ и $\beta = 8$ на одной паре сцен



Строки: сэмплы AE; сэмплы VAE; путь между сценами 0 и 2 при $\beta = 1$; то же при $\beta = 8$ (seed 101).

ОСТАНОВКА 4

Чем отличаются пути при $\beta = 1$ и $\beta = 8$?
Что это говорит об осях?


ЕЩЁ ВОПРОС

Почему у **обычного** автокодировщика интерполяция работает, а сэмплы — нет?



ДИСКРЕТНЫЕ КОДЫ: VQ-VAE

Латентное представление — номера из словаря



VQ-VAE

- словарь **обучаемых векторов**
- фрагмент → **ближайший** вектор словаря
- латентное представление — **номера**

ЧТО ЗАЯВЛЯЮТ АВТОРЫ



- обход **схлопывания** апостериорного распределения
- качественная генерация: изображения, видео, речь

В ЛР 8 схлопывание наблюдалось у **непрерывной** модели (1 seed из 5 без разогрева): проверяйте **каждый seed**.



ЛАТЕНТНОЕ ПРОСТРАНСТВО В STABLE DIFFUSION

Автокодировщик — первая и последняя ступень конвейера



ЧТО ПЕРЕНОСИТСЯ

Эталон, серия seed, проверка **каждого** запуска, диагностика активных осей.


ЧТО ОГРАНИЧЕНО

Качество изображения не выше, чем у **реконструкции автокодировщика**: потери при кодировании не исправляются.



ТИПИЧНЫЕ ЗАБЛУЖДЕНИЯ

Шесть утверждений, которые звучат убедительно




Заблуждение	Что на самом деле
Чем больше вектор, тем лучше	$d: 8 \rightarrow 32$ значимо лишь в 1 наборе из 5; в ЛР 8 реконструкция хуже
Высокий PSNR — хорошая модель	средняя картинка даёт 17,2 дБ: смотрите выигрыш над эталоном
Любой автокодировщик порождает	сэмплы обычного на 8,3–10,5 дБ хуже, чем у VAE
Больше β — чище пространство	$\beta = 8$: 2 активные оси из 8, реконструкция –3,8 дБ
Сферическая интерполяция лучше	на данных ЛР 8: –0,2...–0,5 дБ, значимо нигде
L1 хуже MSE, малая выборка хуже	при 20 эпохах — скорость сходимости; при равных шагах растёт разрыв, а не PSNR



ЧТО ДЕЛАТЬ В ЛР 7–8

ЛР 7 — новый блокнот Colab, ЛР 8 — своя папка в EngEE



ЛР 7 · АВТОКОДИРОВЩИК

- PSNR на тесте и разрыв train – test
- эталон «средняя картинка»
- один из 6 факторов: d , архитектура, потери, шум, выборка
- серия из **5 seed**, допуск до запуска

ЛР 8 · ЛАТЕНТНОЕ ПРОСТРАНСТВО


- VAE: реконструкция, интерполяция, сэмплы, R^2
- один из 6 факторов: β , тип, d , интерполяция, τ
- активные оси, **схлопывание**
- comparison.png — сэмплы и пути

ЛР 7: новый блокнот Colab, T4, ≈ 2 с на модель. ЛР 8: папка в EngEE, процессор, 30–70 с на модель.



КВИЗ: ВОПРОСЫ 1–5

Один верный ответ из четырёх; подсказки — в конспекте



1. Что заставляет автокодировщик оставлять существенное?

A) число эпох

B) узкое место

C) сигмоида на выходе

D) размер пакета

2. У диска 3 независимых фактора. Наименьшее d без потерь?

A) 1

B) 2

C) 8

D) 3

3. PSNR 23,2 дБ, эталон 17,2 дБ. Выигрыш?

A) 6,0 дБ

B) 23,2 дБ

C) 40,4 дБ

D) 17,2 дБ

4. Зачем 160 эпох при 512 сценах в ЛР 7?

A) больше данных

B) быстрее

C) сохранить число шагов (640)

D) поднять PSNR

5. Цель шумоподавляющего автокодировщика?

A) зашумлённый вход

B) чистое изображение


C) случайный шум

D) среднее по выборке



КВИЗ: ВОПРОСЫ 6–10

Один верный ответ из четырёх; подсказки — в конспекте



6. Зачем репараметризация $z = \mu + \sigma \odot \epsilon$?

A) градиент через μ и σ

B) ускорить сэмплирование

C) сократить параметры

D) обнулить KL

7. KL для оси $\mu = 0,5$, $\sigma = 1$?

A) 0,5

B) 0,25

C) 1,0

D) 0,125

8. Почему сэмплы обычного AE хуже (12,9 против 23,3 дБ)?

A) мало эпох

B) большой β

C) разброс μ шире $N(0, I)$

D) нет сигмoиды

9. VAE $\beta = 1$ без разогрева, seed 102: PSNR 17,2, $R^2 \approx 0$. Что это?

A) схлопывание

B) переобучение

C) взрыв градиента

D) ошибка данных

10. Сферическая против линейной интерполяции (ЛР 8)?

A) лучше на 3 дБ

B) значимо везде


C) обе нулевые

D) чуть хуже, значимо нигде

ИТОГИ

Шесть вещей, которые нужно унести с лекции

- автокодировщик сжимает вход в вектор; качество определяет **d относительно числа факторов**
- PSNR — только **рядом с эталоном** «средняя картинка» (17,2 дБ в ЛР 7)
- сравнение при фиксированном числе эпох смешивает эффект и **скорость обучения**
- VAE: реконструкция + $\beta \cdot \text{KL}$; сэмплы **на 8,3–10,5 дБ лучше**, реконструкция хуже
- **схлопывание** (1 из 5 seed без разогрева) ловят по каждому seed и активным осям
- $\beta = 8$ сжимает оси до 2 из 8; сферическая интерполяция **не лучше** линейной





ИСТОЧНИКИ

Названия, первые авторы и даты проверены 19.09.2026

- Kingma D., Welling M. Auto-Encoding Variational Bayes. arXiv:1312.6114, 2013
- Doersch C. Tutorial on Variational Autoencoders. arXiv:1606.05908, 2016
- Burgess C. и др. Understanding disentangling in β -VAE. arXiv:1804.03599, 2018
- van den Oord A. и др. Neural Discrete Representation Learning. arXiv:1711.00937, 2017
- Rombach R. и др. High-Resolution Image Synthesis with Latent Diffusion Models. arXiv:2112.10752, 2021
- Журналы: ЛР 7 — Google Colab, Tesla T4, torch 2.11.0+cu128; ЛР 8 — Engae 26.8.2-H3, процессор, torch 2.4.1; 19–20.09.2026

